第 8 章 信息内容安全

本章学习要点：

- 掌握信息内容安全的概念及关键技术；
- 熟悉信息内容安全面临的安全威胁；
- 了解信息内容安全的相关应用及发展趋势。

8.1 信息内容安全概述

人类社会已经从蒸汽机时代、电气化时代进入信息化时代。据 2023 年中国互联网信息中心发布的第 51 次《中国互联网络发展状况统计报告》，截至 2022 年 12 月，中国网民数量已达到 10.67 亿，互联网普及率达 75.6%。互联网被认为是继报纸、广播和电视等之后的新型信息传播媒体，具有便捷性、即时性、自由性、开放性、虚拟性、交互性等优势。网络俨然成为和现实世界并存的虚拟世界，其具有自由交往和沟通便利等优点，如即时通信、搜索引擎、网上购物、网络社交、网络视频、网络银行、电子邮件等。可见，互联网的发展已经深刻改地变了人们的工作和生活方式。

然而，互联网上信息内容的非法传播和利用将会对社会稳定和国家安全具有较大的影响。2013 年，习近平总书记在《中共中央关于全面深化改革若干重大问题的决定》的说明中进一步指出："随着互联网媒体属性越来越强，网上媒体管理和产业管理远远跟不上形势发展变化。特别是面对传播快、影响大、覆盖广、社会动员能力强的微博客、微信等社交网络和即时通信工具用户的快速增长，如何加强网络法制建设和舆论引导，确保网络信息传播秩序和国家安全、社会稳定，已经成为摆在我们面前的现实突出问题。"在 2019 年，为营造良好的网络信息内容生态，国家互联网信息办公室室务会议审议通过《网络信息内容生态治理规定》。可见，信息内容安全已经成为国家信息安全保障建设的一个重要方面。

8.1.1 信息内容安全的概念

要了解信息内容安全，首先要了解什么是信息内容。1995 年，西方七国信息会议首次提出内容产业(content industry)的概念；到 1997 年，美国发布《北美产业分类系统》中，提出使用信息内容产业；在 1996 年，欧盟提出"INFO 2000 计划"给出了信息内容产业范围："制造、开发、包装和销售信息产品及其服务的产业。"信息内容的主要表现形式包括文本、图像、音频、视频等，如电子文档、网络新闻、电子邮件、JPEG 图像等，具有数字化、多样性、易复制、易分发、交互性等特点。在本书中，信息内容泛指互联网中的半结构化和非结构化数据，包括文本数据和多媒体数据。

目前，国内外关于信息内容安全没有统一的定义。方滨兴院士定义内容安全为："对信息真实内容的隐藏、发现、选择性阻断。"具体要解决的问题包括发现隐藏信息的真实内容、阻断所指定的信息、挖掘所关心的信息；主要的技术手段是信息识别与挖掘技术、过滤技术、隐藏技术等。李建华等定义信息内容安全(information content security)为："研究如何计算从包含

海量信息且迅速变化的网络中，对与特定安全主题相关信息进行自动获取、识别和分析的技术。根据所处的网络环境，又被称为网络内容安全(network content security)。”

总之，信息内容安全指信息内容的产生、发布和传播过程中对信息内容本身及其相应执行者行为进行安全防护、管理和控制。可见，信息内容安全的目标是要保证信息利用的安全，即在获取信息内容的基础上，分析信息内容是否合法，并且确保合法内容的安全，阻止非法内容的传播和利用。其中，国家互联网信息办公室2021年起草了《互联网信息服务管理办法(修订草案征求意见稿)》，第二十六条涉及有关非法内容的限定：反对宪法所确定的基本原则，危害国家安全、荣誉和利益，泄露国家秘密，煽动颠覆国家政权，推翻社会主义制度，煽动分裂国家，破坏国家统一；宣扬恐怖主义、极端主义，宣扬民族仇恨、民族歧视，破坏民族团结，破坏国家宗教政策，宣扬邪教和封建迷信；编造、传播扰乱金融市场秩序的信息，以及其他扰乱市场秩序、经济秩序的虚假信息；编造、传播险情、疫情、警情、自然灾害、生产安全、食品药品等产品安全以及其他方面扰乱社会秩序的虚假信息；仿冒、假借国家机构、社会团体及其工作人员或者其他法人名义散布的信息，或者为实施违法犯罪而冒用他人名义散布的信息；散布煽动非法集会、结社、游行、示威或者其他扰乱社会管理秩序、破坏社会稳定的信息；传播淫秽色情、暴力、赌博、凶杀、恐怖的信息，以及教唆犯罪，传授犯罪手段、方法，制造或者交易违禁物品、管制物品，实施诈骗以及其他违法犯罪活动的信息；侮辱或者诽谤他人，侵害他人名誉、隐私、知识产权或者其他合法权益，以及危害未成年人身心健康，不利于未成年人健康成长的信息；法律、行政法规禁止的其他信息。

8.1.2 信息内容安全威胁

由于互联网的开放性、共享性、动态性、自由性等特点，信息内容安全面临严峻的挑战，涉及政治、经济、文化及健康、保密、隐私、产权等各方面。除了传统的信息安全威胁，如信息内容泄露、篡改、破坏、黑客攻击、计算机病毒等，具体已经在前面章节介绍，信息内容安全还存在以下威胁。

1. 互联网上各种不良信息内容泛滥

当前，网上充斥着大量的不良信息内容，如色情、暴力、反动、赌博、诈骗、诽谤信息等，严重阻碍互联网的健康发展。根据中央网信办违法和不良信息举报中心发布的2022年全国网络举报受理情况统计，2022年度共受理网民举报色情、赌博、侵权、谣言等违法和不良信息1.72亿件，同比增长3.6%。其中，中央网信办举报中心受理举报604.9万件；各地网信举报工作部门受理举报957.3万件；全国主要网站平台受理举报1.57亿件，同比增长4.2%。在全国主要网站平台受理的举报中，主要商业网站平台受理量占58.5%，达9163.6万件。

2. 互联网上垃圾信息内容严重过载

互联网上充斥着各种垃圾信息如垃圾邮件、垃圾短信等，占用了大量的存储资源和带宽，严重影响网络性能和危害用户的合法权益。据报道(https://www.bilibili.com/read/cv24200965)，商业电子邮件(Business Email Compromise，BEC)是一种网络钓鱼欺诈，一直位居全球最具经济破坏性的在线犯罪名单之首。2021年，全球超过70%的企业报告了遭到BEC攻击。2021年美国FBI的互联网犯罪投诉中心(IC3)报告记录了19 954起商业电子邮件泄露/电子邮件账户泄露投诉，详细统计后确认损失近24亿美元。换言之，BEC欺诈占2021年全球69亿美元网络损失总额的近1/3。垃圾邮件和短信等发送的不良信息内容对用户的经济和生活产生了巨大的负面影响。

3. 互联网不良信息内容的传播和利用

网络谣言、网络诈骗、网络暴力等不良信息内容的传播和利用对个人身心健康和社会公共安全造成极大的威胁。从地域来看，互联网信息内容的传播途径主要有两种：一种是信息源在国外，信息内容通过各种途径非法从国外传至国内；另一种是信息源在国内，信息内容非法从国内传至国外。典型的案例如：2006年虐猫人肉搜索事件；2008年柑橘蛆虫事件严重影响全国部分地区销售；2010年金庸被死亡事件；2011年日本核事故泄露引发抢购食盐事件；2014年周星驰被炮轰事件；2015年何炅吃空饷事件；2023年自媒体造谣胡鑫宇事件散播阴谋论；2023年武汉某小学被撞学生的母亲坠楼事件等。可见，不良信息的传播和利用已经成为信息内容安全的一个重要的威胁。

4. 互联网中信息内容侵权行为猖獗

由于信息内容的数字化，在互联网环境下信息内容具有易无损复制、容易篡改、传播成本低等特点，从而模糊了合理使用和侵权行为的界限，使得信息内容版权所有者的合法权益得不到保障，极大地阻碍了信息内容产业的发展。例如，2005年起，美国的作者行会和美国出版商协会指控谷歌扫描和以数字化方式发布各大图书馆藏书内容的计划触犯版权法。在2011年，多名作家控告百度文库在未经许可条件下，将他们的作品放入百度文库平台，免费向公众开放。同年，多家媒体公司控诉百度影音涉嫌视频盗版侵权等。2020年，辽宁丹东苏某等销售侵权盗版教学课件，通过微店将盗版课件销往10多个地区。这些盗版和侵权行为已经成为信息内容产业的主要威胁之一，严重地制约了互联网的发展。

8.1.3 信息内容安全体系架构

信息安全是主要研究信息的机密性、完整性、可用性、可控性及抗抵赖性等安全属性的一门综合性学科。其主要包括设备安全、数据安全、内容安全和行为安全四个层面。信息内容安全作为信息安全在政治、法律和道德层次上的要求，旨在分析和识别信息内容的基础上，解决信息内容利用方面的安全防护，保障对信息内容传播和利用的控制能力。

从学科特点上看，信息内容安全是通用网络内容分析的一个分支，涉及计算机网络、数据挖掘、机器学习、信息检索、中文信息分析、信息论和统计学等多门学科的交叉。根据对信息内容安全定义，按照“获取、分析、管理、控制”的一体化信息内容安全策略，本书给出信息内容安全体系架构如图8.1所示。该体系结构由信息内容获取、信息内容识别与分析、信息内容控制

图8.1 信息内容安全体系架构

和管理等模块构成，系统可实现互联网数据的采集、不良信息内容的分析与识别、不良信息内容的过滤与阻断、敏感信息内容的隐藏，以及信息内容版权保护等功能。

8.2 信息内容获取技术

信息内容获取是数据收集的过程，而如何从互联网中获取有效的信息内容是后续信息内容分析与识别的基础。本节介绍当前主要的两种主要的信息内容获取技术：信息内容主动获取技术和信息内容被动获取技术。

信息内容主动获取技术是通过向网络中注入数据包后的反馈来获取信息，其特点是接入方式简单、能广泛获取信息内容，但会对网络造成额外负荷，如搜索引擎技术。信息内容被动获取技术是将设备介入网络的特定部位进行获取，在网络出入口上通过镜像或旁路侦听方式获取网络信息，其特点是接入需要网络管理者的协作，获取的内容仅限于进出本地网络的数据流，但不会对网络造成额外流量，如网络数据包捕获技术。还有学者介绍了数据挖掘技术的主动信息内容获取技术，以及信息推荐的被动信息内容获取技术。本书分别以搜索引擎技术和网络数据包捕获技术两种常用的技术为代表，介绍网络信息内容主动和被动获取的相关技术原理和过程。

8.2.1 信息内容主动获取技术

本节以搜索引擎技术为例，阐述互联网信息内容的主动获取技术的原理和过程。在互联网发展初期，网站数量相对较少，从互联网上获取信息相对容易；然而，随着互联网爆炸性发展，用户难以从海量信息中找到满足需求的资料信息，Web 信息检索在此背景下应运而生，搜索引擎作为最常见的 Web 信息检索系统在实际生活中得到广泛的应用。

1. 搜索引擎发展概述

1990 年加拿大 McGill University 的学生 Alan Emtage、Peter Deutsch、Bill Wheelan 开发了 Archie。1993 年 Matthew Gray 开发了第一个“机器人(robot)”程序 World Wide Web Wanderer，该程序在 Web 上沿着网页间的链接关系爬行，又称为“蜘蛛(spider)”，起初用于统计互联网上服务器的个数，后来发展到能检索网络域名。在此基础上，1994 年 Brian Pinkerton 开发出第一个支持全文搜索引擎 WebCrawler，在这一年里，Michael Mauldin 将 John Leavitt 的 Spider 程序接入其索引程序中推出搜索引擎 Lycos；Stanford University 的两名博士生 David Filo 和美籍华人杨致远共同创办了雅虎公司。1998 年发布的采用 PageRank 技术的谷歌搜索引擎已成为全球最受欢迎的搜索引擎。2000 年，几位美国留学华人回国创业推出了百度搜索引擎。2003 年，中国搜索 CEO 陈沛提出了第三代搜索引擎的概念，并于 2004 年推出网络猪；2011 年，他正式推出中搜第三代搜索引擎平台。2023 年，微软公司发布了新版必应搜索引擎，采用了 ChatGPT 开发商 OpenAI 的人工智能技术。当前，有较多的公司加入到搜索引擎的研究和开发中，常用的搜索引擎有：谷歌、百度、雅虎、Bing 等。

2. 搜索引擎概念及分类

搜索引擎(search engine)是一种在 Web 上应用的软件系统，它以一定的策略在 Web 上搜集和发现信息，在对信息进行处理和组织后建立数据库，为用户提供 Web 信息查询服务。即搜索引擎后台通过爬虫程序遍历 Web，同时下载和存储分布在 Web 上的信息，并建立相应的索引记录；前端为用户提供网页界面，接受用户的查询请求，根据建立的索引按照一定的排列

顺序为用户提供信息检索服务。

根据工作原理，搜索引擎可分为：全文搜索引擎(full text search engine)、目录式搜索引擎(directory search engine)和元搜索引擎(meta search engine)。全文搜索引擎是通过将互联网上抓取的网站信息存入数据库并建立索引，然后查找满足用户需求的记录信息，并按照一定的排列顺序返回给用户，是真正意义上的搜索引擎，如 Google、Baidu 等。目录式搜索引擎是通过人工或半自动化方式发现信息，依靠编目员的知识将信息划分到事先已确定的分类框架中，用户不需要进行关键字查询，仅依靠分类目录即可找到所需要的信息，如雅虎、搜狐等。元搜索引擎通过一个统一的用户界面，调用多个搜索引擎进行搜索，然后将这些搜索引擎的查询结果经过归并、去重等处理后返回给用户，如 InfoSpace、Dogpile 等。

根据搜索范围，搜索引擎可分为：综合搜索引擎和垂直搜索引擎。综合搜索引擎为通常意义上的引擎，可根据用户的需求检索任何类型、任何主题的资源；垂直搜索引擎是针对某特定领域的结构化内容的搜索引擎，是对 Web 信息中的某类专门的信息进行处理、整合，定向分字段抽取出需要的数据进行处理后再以某种形式返回给用户的搜索方式，如去哪儿搜索引擎等。

3. 搜索引擎体系结构及工作流程

搜索引擎技术是要在考虑信息的关联性的基础上，尽可能地使搜索效率高、搜索结果全面、搜索准确度高。当用户提交查询请求时，搜索引擎并不真正搜索整个互联网，而是搜索事先已整理好的网页索引数据库，其体系结构如图 8.2 所示。

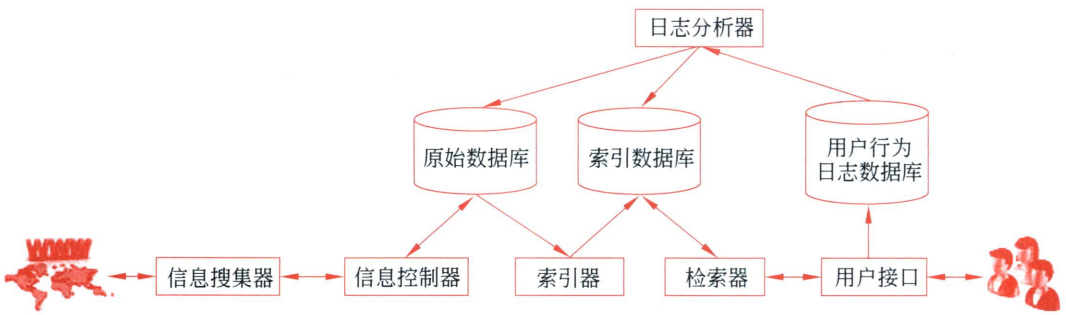

图 8.2 搜索引擎体系结构

根据每个部件功能的划分，将搜索引擎的体系结构进行抽象，其三段式工作流程如图 8.3 所示，主要由网页搜索、预处理和检索服务三部分组成。

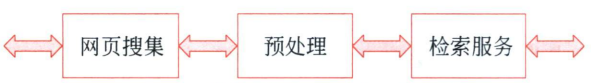

图 8.3 搜索引擎三段式工作流程

(1) 网页搜集。该阶段主要用来抓取网页信息，存入数据库，是搜索引擎提供信息检索服务的基础。网页信息的抓取一般是将网页集合抽象为一个有向图模型，然后按照一定的策略进行，该部分是本节讨论的重点，详细过程将在下部分进行介绍。在将网页内容存入数据库，对数据库维护的基本策略包括批量搜集和增量搜集两种形式。批量搜集是用每一次搜索的结果替换上一次的内容，其主要优点在于系统实现简单，然而容易因重复搜索带来额外的带宽消耗，同时时新性不强。增量搜集是开始搜索一批，后来只搜索有改变的网页和新出现的网页，同时删除上次搜索后不再存在的网页，其具有较高的时新性，但系统实现较为复杂。

（2）预处理。在建立好网页数据库后，要提供网页信息检索服务，需要对网页数据库进行预处理，具体包括关键词提取、网页消重、链接分析和索引构建四部分。①关键词提取主要将网页文档进行分词处理和表示后，找出能代表文档内容的特征词。②网页消重用来克服查询结果中内容重复或主题内容重复的问题，有效缓解网页检索时间和带宽，提高用户体验。③链接分析通过分析网页之间的关联关系可解决基于内容搜索引擎搜索不到的结果，同时可判断网页的相对重要程度。④索引构建主要利用关键词集合和文档编号形成倒排文件结构作为网页的组织结构，其中可将文档作为索引目标结构，文档中的关键字作为索引。

（3）检索服务。检索服务是在网页搜索和预处理的基础上，根据用户的需求得到检索结果，并按一定的排列顺序返回给用户。因此，该阶段主要包括：查询方式和匹配、结果排序及文档摘要生成。①查询方式和匹配主要刻画用户的查询信息需求，一般采用一个词或短语来表达，对于短语需要进行分词处理；然后按照信息检索模型（如集合论模型、代数论模型及概率模型等）匹配查询需求关键字和已经建立的索引关键字。②结果排序指根据查询结果与用户需求之间的相关性，按照信息的重要程度对返回的结果进行排序的过程，排序方法有倒排文件、PageRank、HITS 等。③文档摘要是构成每条查询结果的元素之一，其他还包括标题和网址，主要的生成方法包括静态方法和动态方式。静态方式按照某种规则，在预处理阶段就从网页内容中提取部分文字作为摘要；动态方式是在响应查询时，根据查询词在文档中的位置，提取周围的文字作为摘要。

4. 网络信息抓取技术原理

本部分重点介绍利用搜索引擎从网页上获取信息内容的技术原理，即搜索引擎体系结构中的信息搜索器，又被称为网络爬虫（web crawler）或网络蜘蛛（web spider）。

实质上，网络爬虫是一个基于 HTTP 协议的网络程序，其主要工作原理是：将初始的 URL 集合放入一个待爬行的 URL 队列中，然后按照一定的顺序从中读取 URL，解析出此 URL 中主机名对应的 IP 地址，使用 HTTP 协议指向此 IP 地址所对应的 Web 服务器，下载此 URL 对应的网页并将该 URL 放入已抓取 URL 集，然后分析页面内容，提取页面中所有的链接 URL，对于提取到的每个链接 URL，判断是否已经在已抓取 URL 集合中，对于新的 URL 则加入到待爬行的 URL 队列中，重复该过程，获取更多的页面，直到待爬行的队列为空，具体如图 8.4 所示，该过程为通用网络爬虫，大多数爬虫算法均遵循该工作流程。

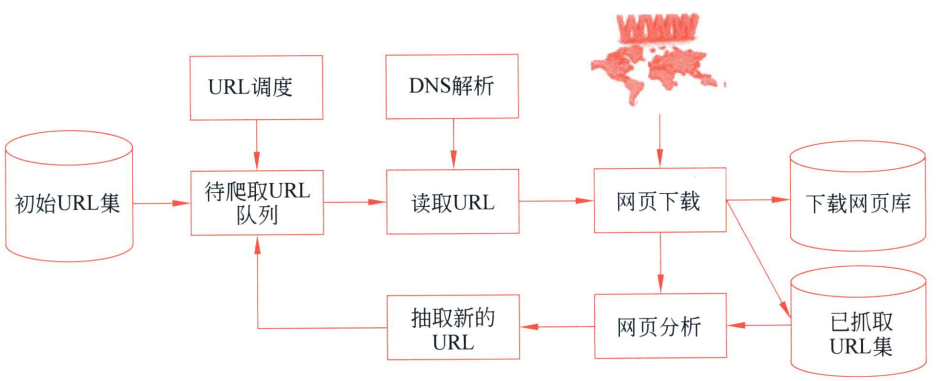

图 8.4　网络爬虫工作流程

除此之外，网络爬虫还包括批量型爬虫（batch crawler）、增量型爬虫（incremental crawler）及垂直型爬虫（focused crawler）。具体而言，批量型爬虫具有比较明确的抓取范围和

目标，当达到所设定的目标后，爬虫程序即停止；而增量型爬虫会持续不断地抓取新网页，并更新已有的网页；垂直型爬虫则是抓取特定主题内容或特定领域的网页。

在网络爬虫中，另一个很重要的问题是如何对待抓取 URL 队列中的 URL 进行调度，即先抓取哪个页面，后抓取哪个页面。而决定这些 URL 排列顺序的调度方法即为网页抓取策略或网络爬虫搜索策略。目前，常见的网络爬虫搜索策略如下。

（1）深度或广度优先搜索策略。网页之间的关系可抽象为图模型，因此可将图论中的深度优先算法和广度优先算法应用到网络爬虫中。深度优先搜索策略是从选定页面中未处理的某个超链接出发，按照一条链接接着一条链接地搜索下去，直到搜索完该超链接，之后才从另外一个超链接开始重复该搜索过程，直到所有初始页面的所有超链接都被处理完。该搜索策略容易导致爬虫的陷入问题，即进入之后，无法出来。广度优先搜索策略是将新的 URL 放到待抓取队列的队尾，优先抓取某网页中链接的所有网页，然后选择其中的一个链接网页，继续抓取在此网页中链接的所有网页。目前，网络爬虫大都使用的是广度优先搜索策略。

（2）非完全 PageRank 策略。这种策略将下载的网页和待抓取 URL 队列合在一起形成网页集合，在该集合内部进行 PageRank 值的计算，然后按照 PageRank 值对待抓取 URL 进行排序，得到的结果即为网络爬虫每次读取 URL 的顺序。PageRank 是在下载完所有的网页之后，计算得到的排序结果才是可靠的。然而，网络爬虫在运行过程中只能得到部分网页，因而计算得到的结果是不可靠的，这也是非完全 PageRank 的原因。

（3）OPIC(online page importance computation)搜索策略。OPIC 的思想和 PageRank 的思想类似，在算法开始之前，给每个页面相同的“现金”(cash)，当下载某个页面后，该页面将自己的现金平均分配给其所包含的链接页面，并清空自己的现金。最后，根据每个页面所拥有的现金值，来决定待抓取网页页面的下载顺序。

（4）大型网站优先搜索策略。考虑到大型网站的内容质量大都比较高，并且通常包含较多的页面，对待爬取的 URL 队列，大型网站优先搜索策略优先下载等待下载页面较多的大型网站的页面和链接。

总体而言，网络爬虫作为网络信息内容主动获取的一种方式具有易于实现、采集到的数据具有一定的相关度且易于分析。但容易消耗 Web 服务器的服务资源，并且采集的数据大都是 Web 网页数据，对于即时通信信息、邮件等数据具有一定的局限性。

8.2.2 信息内容被动获取技术

信息内容被动获取通过旁路侦听、被动接受等方式获取网络信息内容。本节以常见的网络数据捕获技术为例介绍网络信息内容被动获取技术原理。相比于网络爬虫的信息内容主动获取技术，网络数据包捕获能有效捕获除 Web 之外的更加丰富的信息，并且对网络造成的负载较少，对正常网络服务的影响较小。

8.2.2.1 网卡工作模式

以太网是 DEC、Intel 和 Xerox 公司在 1982 年联合制定的一个标准，是当前 TCP/IP 采用的主要的局域网技术。以太网是由一条总线和多个连接在总线上的网络设备构成，基本的传输单元是数据帧。通过网卡采用载波侦听/冲突检测(CSMA/CD)的方式来发送数据。网卡的硬件地址(MAC 地址)大多数采用 48 位，用来唯一标识网络上的设备。在以太网中，所有的通信方式都是广播的，即在同一网段的所有网卡均可收到总线上传输的数据，因此可通过设置网卡进行网络数据包捕获。具体而言，网络数据包捕获即是通过物理接入网络的方式在网

络的传输信道上获取数据。当前，网卡有以下四种工作模式。

(1) 广播模式：目的地址为 0xFFFFFF，网卡能够接收网络中的广播帧。

(2) 组播模式：网卡能够接收组播数据。

(3) 直接模式：只有目的网卡才能接收该数据。

(4) 混杂模式：网卡能够接收一切通过它的数据，而不管该数据是不是传给它。

在系统正常工作情况下，网卡只响应目标地址与自己 MAC 地址相匹配的数据帧以及目的地址是广播地址的数据帧，其余情况的数据帧都将被丢弃。为此，在开始捕获网卡上传输的数据包之前，需要将网卡工作模式设置为混杂模式。在该模式下，对收到的每一个数据帧都产生中断，使得操作系统能直接访问数据链路层捕获相关的数据。

8.2.2.2 网络数据包捕获原理

数据包捕获机制主要由最底层针对具体操作系统的包捕获机制、包过滤机制和最高层的用户程序接口组成。不同操作系统所对应的最底层的包捕获机制有所不同。从形式上看，数据包都是经网卡、设备驱动层、数据链路层、IP 层、传输层，最后传送给应用程序。最底层的包捕获机制是在数据链路层增加一个旁路处理，对发送和接收的数据包做过滤和缓冲等相关处理；包过滤机制按照用户的需求，对捕获的数据包进行筛选，将满足条件的数据包发送给应用程序。对用户程序而言，包捕获机制提供了统一的程序接口，用户可通过调用相应的函数捕获相应的数据包。

在底层包捕获机制方面，以太网中不同的信息交换方式使得网络数据捕获的处理方式不同，可分为以下几类。

(1) 共享式以太网网络数据包捕获。共享式以太网通过共用一条总线或集线器实现网络互联，典型的代表是使用 10Base2 或 10Base5 的总线型网络和以集线器为核心的 10Base-T 星状网络。集线器工作在物理层，实现对网络的集中管理，同时对接收到的信号进行再生、整形和放大，以扩大传输距离。本质上，以集线器为核心的以太网和总线型以太网没有区别，通过集线器连接的每个网络设备均能收到所有的数据。因此，将任意一台设备的网卡设置为混杂模式，便可监听同一网络内所有设备发送的数据，达到网络数据捕获的目的。

(2) 交换式以太网网络数据包捕获。交换式以太网通过交换机连接网内各设备，交换机通过每个端口发送来的数据帧，形成源 MAC 地址和端口对应 MAC 地址表，当一个新的数据帧到达交换机时，根据目的 MAC 地址查找这张 MAC 地址表并转发到相应的端口。可见，交换式以太网中只有目标端口的设备能接收到相应的数据包。在广播模式下，数据帧将发往所有的端口。交换机端口隔离了网络设备之间数据帧的传输，限制了通过侦听来捕获数据的功能。因此，实现交换式以太网中网络数据包捕获的典型方法包括端口镜像、ARP 欺骗和 MAC 洪泛等。简单而言，端口镜像是将一个端口的流量自动复制到另一个端口；ARP 欺骗是分别向目标设备和网关发送 ARP 包，欺骗目标设备和网关刷新本地的 IP-MAC 对应表，使得所有数据包都经过监听设备；MAC 洪泛指当交换机设备的内存耗尽时候，便向连接的所有链路发送数据包。

下面介绍共享式以太网网络数据包捕获，即在将网卡设置为混杂模式后，在 Windows 平台下的网络数据捕获方法。

8.2.2.3 基于 Windows 的网络数据捕获方法

在 Windows 操作系统下，网络数据包捕获方法有：基于原始套接字的、基于 NDIS 驱动

程序的、基于 WinPcap 的等。

1. 基于原始套接字(raw socket)的网络数据捕获

应用层通过传输层进行数据通信时，存在多个应用程序并发使用 TCP 或 UDP 的情况。为有效区分不同应用程序和连接，计算机系统为应用程序和 TCP/IP 之间的协议交互提供了称为套接字(socket)的接口。套接字地址由 IP 地址与端口号来唯一确定，其中 IP 地址用于找到目的主机，端口号用来标识进程，即同一主机上不同应用程序由不同的端口号来确定。创建一个套接字需要三个参数：目的 IP、传输层协议(TCP 或 UDP)、端口号。当前，套接字分为三种类型：①流式套接字(SOCK_STREAM)，是一种面向连接的套接字，对应于 TCP 应用程序；②数据包套接字(SOCK_DGRAM)，是一种无连接的套接字，对应于 UDP 应用程序；③原始套接字(SOCK_RAW)，是一种能直接对 IP 数据包进行处理的套接字，能完成流式套接字和数据套接字不能完成的功能，如捕获和创建 IP 数据包等。通过使用原始套接字实现网络数据捕获，其具体流程图如图 8.5 所示。

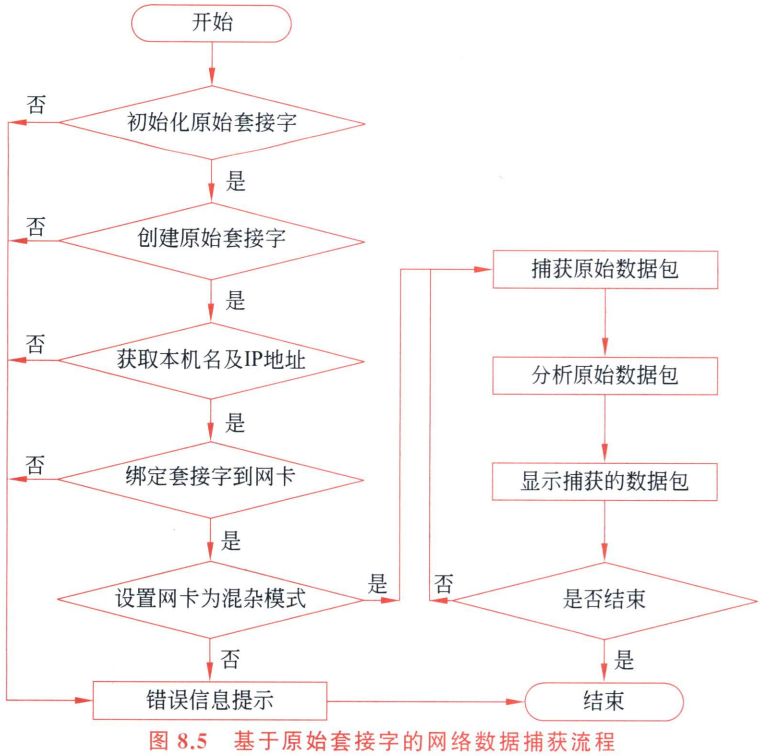

图 8.5 基于原始套接字的网络数据捕获流程

在创建原始套接字之前，需要调用函数 WSAStartup 实现套接字库的初始化，然后可利用函数 socket()或 WSASocket()来创建套接字。这两种方法都可以创建一个套接字，不同之处在于 WSASocket()函数具有重叠 I/O 功能，即在发送和接收数据操作可以被多次调用；而 socket()函数只能发过之后等待响应消息后才可做下一步操作。在此基础上，通过 bind()函数将创建好的原始套接字与网卡进行绑定；要利用原始套接字捕获网络数据包，还需要通过函数 ioctlsocket()或 WSAIoctl()将网卡设置为混杂模式，其中 WSAIoctl()函数在 Winsock2 中将 ioctlsocket()函数中的 argp 参数分解成一系列输入函数。若网卡的混杂模式设置成功，则返回 0；否则可通过 WSAGetLastError()函数返回相应的错误提示消息。最后可以捕获到流经网卡的所有数据包，并进行进一步分析和显示等功能，直到程序终止。

2. 基于 NDIS 驱动的网络数据捕获

网络驱动接口规范(Network Driver Interface Specification，NDIS)的早期版本是由 Microsoft 和 3COM 公司联合开发，现主要用于 Windows 平台。NDIS 定义了网卡或网卡驱动程序与上层协议驱动程序之间的通信接口规范，屏蔽了底层物理硬件的差异性，使得上层协议驱动程序可以以一种与设备无关的方式与网卡驱动程序进行通信。NDIS 横跨传输层、网络层和数据链路层，支持三种网络驱动程序：微端口(网卡)驱动程序(miniport driver)；传输协议驱动程序(protocol driver)，如 TCP/IP 协议栈；中间层驱动(intermediate driver)，位于微端口驱动程序和传输协议驱动程序之间，各个驱动层之间的结构关系如图 8.6 所示。

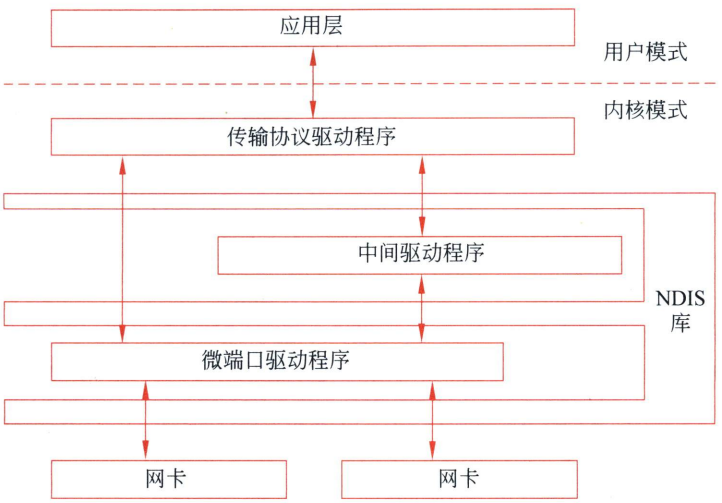

图 8.6　NDIS 层次结构

微端口驱动程序通过 NDIS 库向下与底层网卡进行通信，向上与中间驱动程序或协议驱动程序交互。NDIS 库提供了函数集 NdisXxx 封装了微端口需要调用的操作系统函数，同时对外提供了入口函数集 MiniportXxx。中间驱动程序要实现与下层的微端口驱动程序和上层的协议驱动程序之间的通信过程：①向下提供了协议入库点函数集 ProtocolXxx，NDIS 调用这些函数传递下层微端口的请求；②向上提供了微端口入口函数集 MiniportXxx，NDIS 通过调用这些函数实现与协议驱动程序通信。因此，对于上层的驱动，其是微端口驱动程序；对于底层的驱动程序，其是协议驱动程序。传输协议驱动程序是 NDIS 层次结构的最高层，但被当作传输层协议的传输驱动程序的最底层：①向下与中间驱动程序和微端口驱动程序交互，将用户发来的数据复制到数据包中，然后通过调用函数集 NdisXxx 将数据包发送给中间驱动程序或微端口驱动程序；同时协议驱动程序也提供了一套入口点函数集 ProtocolXxx，用来接收由底层传来的数据包。②向上提供了一个传输驱动程序接口 TDI，用来与上层的应用层进行交互。

总体而言，中间层驱动程序对上层协议驱动程序表现为一个虚拟的微端口网卡驱动(miniport driver)，对下层的微端口驱动程序表现为一个协议驱动(protocol driver)。所有经过网卡发送到网络和从网络接收的数据包都要经过中间驱动程序，因此在此处可以实现数据包的捕获。具体的方法如下。

首先，通过 DriverEntry()函数调用 NdisMInitializeWrapper()函数使得微端口驱动和 NDIS 相联系，返回设备句柄 NdisWrapperHandle；然后，利用该句柄调用 NdisIMRegisterLayeredMiniport()函

数为 NDIS 中间层驱动程序注册回调函数集 MiniportXxx，使得上层协议将其当作网卡，并通过 NDIS 库调用这些回调函数；最后，调用 NdisRegisterProtocol()函数为中间驱动程序注册回调函数集 ProtocolXxx，使得下层网卡将其当作是一个协议，并通过 NDIS 库调用这些回调函数。

当底层网络有数据到达时，将触发中断，通过调用 NdisMIndicateReceivePacket()函数接收数据包，并放入微端口驱动的缓冲区中，当接受的数据达到一定数量时，微端口驱动会告知 NDIS 新数据的到来，此时，将触发 NDIS 中间驱动程序调用 ProtocolReceivePacket()函数来接收数据包，之后，可以再次请求 NDIS 告知协议驱动程序来接收数据。可见，在 NDIS 中间驱动程序即可以实现对网络数据包的捕获和处理。

3. 基于 WinPcap 的网络数据捕获

WinPcap(Windows packet capture)是 Windows 平台下的一个免费的网络访问系统，可在其官网上下载相应的版本。WinPcap 是 UNIX 系统下 Libpcap 在 Windows 下的移植，屏蔽了不同 Windows 系统的差异，主要用来提供底层原始网络数据包捕获、过滤、发送和分析等功能，广泛应用于网络协议分析、流量监控、安全扫描和入侵检测等方面。

WinPcap 体系结构由 3 部分组成：内核模式下的网络组包过滤器(Netgroup Packet Filter，NPF)、用户模式下的低级动态链接库 Packet.dll 和高级系统无关动态链接库 Wpcap.dll，具体如图 8.7 所示。

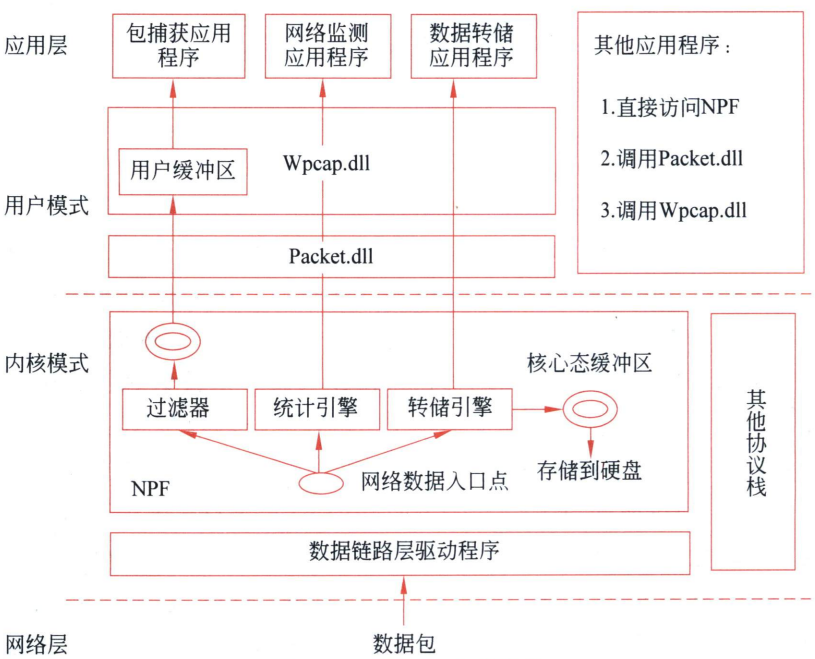

图 8.7 WinPcap 内部结构

上文介绍的 NDIS 主要实现上层协议驱动程序以一种与设备无关的方式与网卡驱动程序进行交互。网络组包过滤器 NPF 即被实现为一个协议驱动程序，是 WinPcap 的核心。为了捕获网络上的原始数据包，其绕过了操作系统的协议栈，直接与网卡驱动程序交互。主要实现从网卡驱动程序收集网络数据包，转发给过滤器进行过滤，也可以发送给统计引擎进行网络统计分析，还可以发送到转存器，将网络数据包存储到磁盘。NPF 与操作系统有关，在 Windows 95/98/ME 系统中，以 VxD 文件存在；在 Windows NT/2000 中，以 SYS 文件存在。两个动态链接库 Packet.dll 和 Wpcap.dll 均工作在用户模式，其中低级动态链接库 Packet.dll 用来屏蔽

不同 Windows 版本中用户模式和内核模式之间接口的差异，为 Windows 平台提供一个能直接访问 NPF 且与系统无关的公共接口。高级系统无关动态链接库 Wpcap.dll 是一个独立于底层驱动程序和操作系统更加高层的编程接口。用户既可以使用包含在 Packet.dll 中的低级函数进入内核级调用，也可以使用由 Wpcap.dll 提供的高级函数调用。但应用程序调用 Wpcap.dll 函数时，Packet.dll 中的函数也会被自动调用。

利用 WinPcap 实现网络数据包捕获主要是通过调用 Wpcap.dll 和 Packet.dll 中提供的 API()函数实现，具体流程如图 8.8 所示。首先通过调用函数 pcap_findalldevs()来获取网络设备列表，得到设备的基本信息。然后，通过调用函数 pcap_open_live()来打开指定的网卡设备，设置网卡的工作模式为混杂模式。在此基础上，通过函数 pcap_compile()和 pcap_setfilter()的配合，可实现满足用户需求的数据包过滤，其中 pcap_compile()函数将一个高层的布尔过滤表达式编译成一个能够被过滤引擎所解释的低层的字节码；pcap_setfilter()函数将一个过滤器与内核捕获会话相关联。通过调用 pcap_setfilter()函数，过滤器将应用于网络的所有数据包，只有符合要求的数据包才被传送给应用程序。最后进行数据包的捕获，WinPcap 提供了多种网络数据包捕获函数，有的基于回调机制，如调用 pcap_loop()；有的采用直接方式，如调用 pcap_next_ex()。

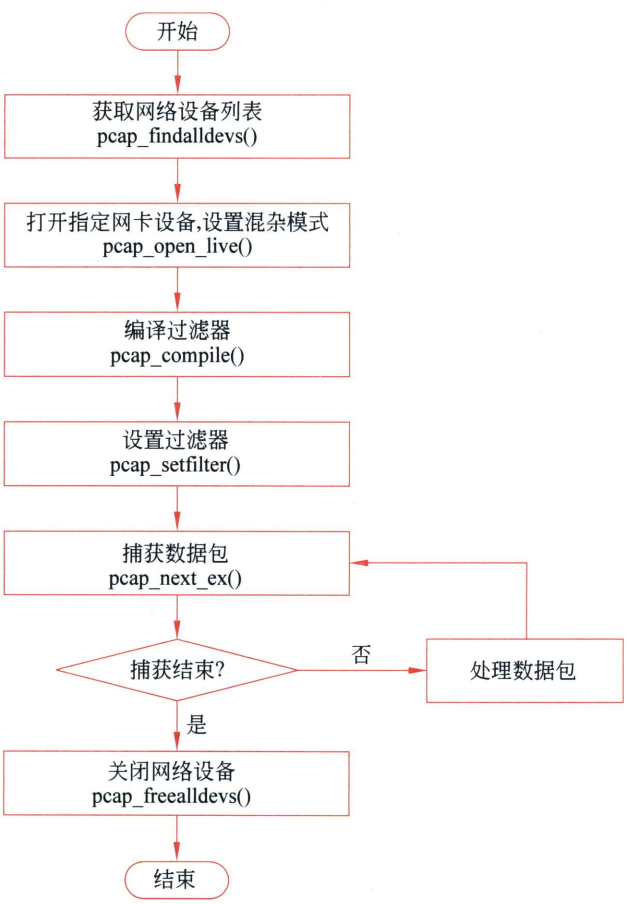

图 8.8　基于 WinPcap 网络数据包捕获流程

8.3 信息内容识别与分析

在获取网络信息内容的基础上，需要对信息内容进行识别和分析，判断信息内容的合法性。根据信息内容的类型，本节主要以文本和图像两方面为例，介绍信息内容的识别与分析技术，为后面对信息内容进行控制和管理奠定基础。

8.3.1 文本内容识别与分析

当前，信息内容大都表现为半结构化或非结构化的电子文本形式，如网页、邮件、新闻、短信等。在对文本内容分析之前，首先介绍文本数据、文本信息和文本知识的概念。

定义 8.1 文本数据（Textual Data，TD）：面向人的，可以被人部分理解，但不能为人所利用，具有自然语言固有的模糊性与歧义性。

定义 8.2 文本信息（Textual Information，TI）：面向机器的，将隐含在文本数据的关系以显式的方式展现给用户，具有无歧义性、显性关系等特点。

定义 8.3 文本知识（Textual Knowledge，TK）：对文本信息进行处理得到有意义的模式，对人来说是可理解的和有用的。

可见，通过信息获取技术得到的原始文本要用于信息处理，必须通过文本预处理技术实现文本数据到文本信息的转换，将文本由面向人的转换为面向机器可识别的信息。一般地，文本内容预处理包括文本分词、去停用词、文本表示和特征提取四个步骤，如图 8.9 所示。经过预处理后，原始文本数据从一个半结构化或无结构化转换为结构化的计算机可识别的文本信息，即对文本进行抽象，建立数学模型，用来描述和替代原始文本，使得计算机能够通过该对模型的计算和操作实现对文本的识别。由此可见，该过程为后续文本知识发现奠定了基础。

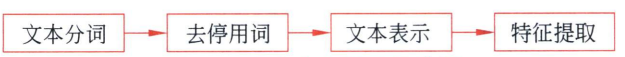

图 8.9 文本内容预处理过程

8.3.1.1 文本分词

文本分词处理对象包括英文文本和中文文本两类，其中词是最小的、可独立运用的、有意义的语言单位。

在英文文本分词中，单词被当作基本处理单元，单词与单词之间通过空格隔开，因此最为简单的方法使用空格与标点作为分隔符。在中文文本分词中，字作为基本书写单元，字与字连接起来形成词来表达意思。然而，中文文本中的分隔符（逗号“，”、冒号“：”、句号“。”、顿号“、”、感叹号“！”和问号“？”等）一般用来分割短语或句子，词与词之间没有明显的分隔符。因此，中文分词是将中文连续的字序列按照一定规范重新组合成有意义的词序列的过程。对文本进行有效的分词是实现人与计算机沟通的基础，也是文本内容处理的基础。目前，文本分词技术已经广泛应用于信息检索、文本挖掘、机器翻译、语音识别等领域。

当前，中文分词面临两个主要问题：歧义识别和未登录词识别。

（1）歧义识别问题。中文分词歧义主要包括交叉型歧义和组合型歧义，其中交叉型歧义指两个相邻的词之间有重叠的部分。例如，对于字串 ABC，如果其子串 AB、BC 分别为两个不同的有意义的词，那么对 ABC 进行切分，既可以切分成 AB/C，也可以切分成 A/BC，则称 ABC 存在交叉型歧义。组合型歧义指某个词组其中的一部分也是一个完整的有意义的词。

例如，对于字符串 AB，如果 AB 组合起来是一个词，同时其子串 A、B 单独切分开也成为有意义的词，则称 AB 存在组合型歧义。

（2）未登录词识别问题。分词的好坏依赖于词典所录词的多少。在语言的发展和变化中会出现很多新词，同时词的衍生现象也很普遍，因此任何一个词典都不可能包含所有的词。未登录词是没有加入分词词典而实际文本中存在的词汇。一般而言，未登录词大致包含两类：一类是专有名词，如人名、地名、产品名、简称等；另一类是新出现的通用词汇和专业用语，如神马、给力等。

为解决上述两个问题，常见的中文分词技术可分为如下几种。

1. 基于字符串匹配的分词方法

基于字符串匹配的分词方法又称机械分词法，其基本思想是：首先建立词典，一般用汉字字典，然后对于给定的待分词的汉字串 S，按照一定的扫描规则（正向/逆向）取 S 的子串，最后按照一定的匹配规则将此子串与词典中的某词条进行匹配。若成功，则该子串是词，继续分割剩余的部分，直到剩余部分为空；否则，该子串不是词，则取 S 的子串进行匹配。可见，此法按照扫描方向可分为正向匹配法和逆向匹配法，按照不同长度优先分配可分为最大匹配法和最小匹配法。

目前常见的实现方法有正向最大匹配法、逆向最大匹配法、最少切分分词法和双向匹配法。这里以正向最大匹配法为例介绍基于字符串匹配的分词方法；逆向最大匹配法的思想与之类似，只不过扫描规则是逆向的；双向匹配法是这两种方法的结合；最小切分分词法是使每一句中切出的词数最小。

基于字符串正向最大匹配分词方法是按照从左到右的正向规则将待分词的汉字串 S 中的几个连续字符与词典中的词进行匹配，若成功，则并不是马上切分出来，而是继续进行匹配，直到下一个扫描不是词典中的词才进行词的切分，从而保证了词的最大匹配。一般地，可通过增字匹配法或减字匹配法来实现。若词典中最长词的长度是 MaxLen，以减字匹配法为例说明基于字符串正向最大匹配分词方法的实现过程，详细流程如图 8.10 所示。

可见，利用最大匹配法进行中文分词实现简单，分词速度也比较快，但是分词的精度依赖于词长。若词长过短，长词就会被切错；词长过长，查找效率降低。此外，也不能发现交叉型歧义，如利用最大匹配法对“小组合解散”进行分词，得到的结果为“小组/合/解散”或“小/组合/解散”。

2. 基于统计的分词方法

这类方法主要考虑词是稳定的字的组合，即在上下文中，相邻字之间同时出现的次数越多，就越可能构成一个词，故可以计算文本中相邻出现的各个字的组合频率，计算它们的互现信息，并以此来判断它们组合成一个词的可信度。字与字之间互现信息的高低直接反映了这些字之间的紧密程度。当紧密程度高于某一阈值时，即可认为此字组可能构成了一个词。

由此可见，这种方法只需要对语料中字的组合频度进行统计，不需要基于切分词典，因此被称为无词典分词方法或统计取词方法。具体的统计方法可采用 N-gram、隐马尔可夫模型和最大熵模型等，这里不做详细的介绍。然而，这种方法经常抽出一些共现频度高，但并不是词的常用字组，如“之一”“有的”“我的”等，可见，该方法对常用词的识别精度差。此外，由于需要统计语料中字的组合频率，因而需要较大的存储空间。

3. 基于理解的分词方法

这类方法的基本思想是在分词中考虑句法和语义信息，利用句法信息和语义信息来消除歧义。也就是说，这种方法通过计算机模拟人对句子的理解实现中文分词过程。一般地，该方

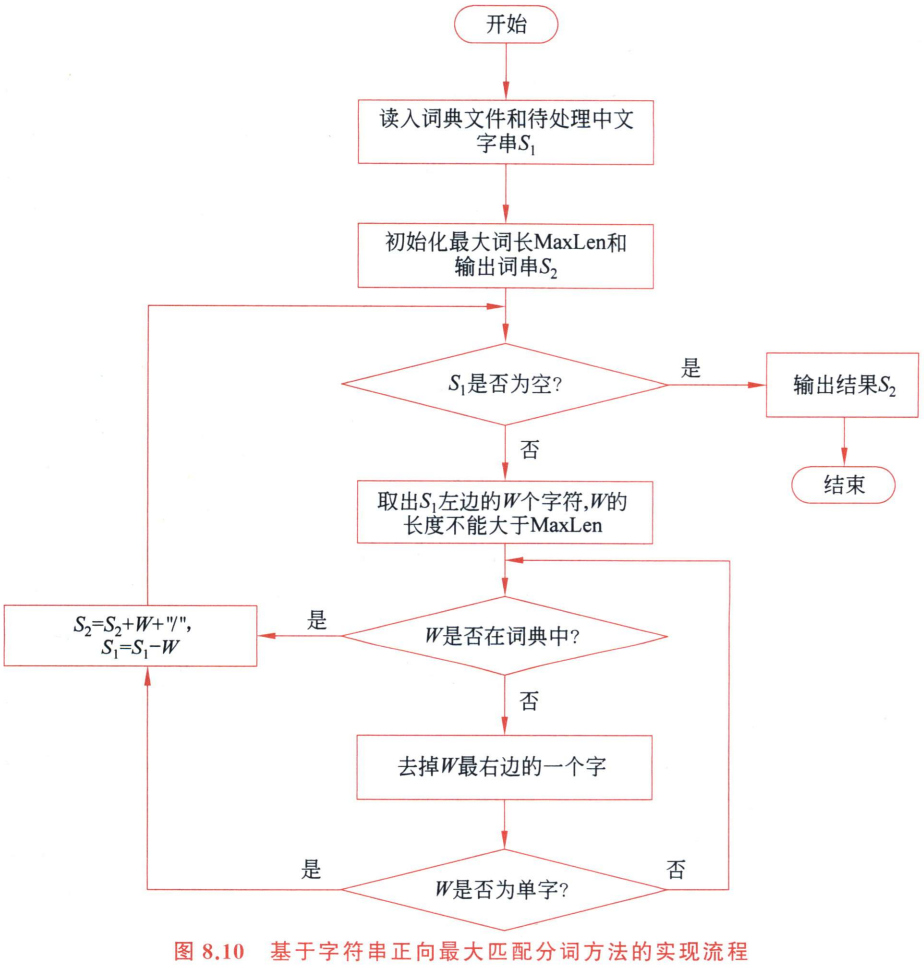

图 8.10　基于字符串正向最大匹配分词方法的实现流程

法由分词子系统、句法语义子系统、总控部分组成。在总控部分的协调下，分词子系统可以从句法语义子系统那里获得有关对词、句子等的句法和语义信息，从而能有效解决分词过程中的歧义问题。

然而，由于中文语言的笼统性和复杂性，使得计算机无法将各种语言组织成计算机能够处理的形式。因此，尽管该方法的初衷较好，但目前并没有得到广泛的应用。

总体而言，这三类分词方法各有各的优缺点，表 8.1 对这三种方法进行了比较，特别是在应对中文分词所面临的两个主要问题方面。

表 8.1　三类分词方法的比较

分类	基于字符串匹配的分词方法	基于统计的分词方法	基于理解的分词方法
优点	1. 实现简单； 2. 分词速度快	1. 不需要基于切分词典； 2. 消除歧义	1. 能识别未登录词； 2. 消除歧义
缺点	1. 分词精度与词库相关； 2. 不能发现交叉型歧义； 3. 不能识别未登录词	1. 经常抽出一些共现频度高但不是词的常用字组； 2. 不能识别未登录词； 3. 识别精度差，时空开销大	1. 知识词库复杂； 2. 分词精度与知识库相关

8.3.1.2 去停用词

在文本分词的基础上，需要去掉那些常见的、价值不大的词，即去停用词(stop words)。去停用词能在不影响系统精度的前提下，有效节省存储空间和计算时间。常见的停用词包括冠词、介词、连词。

目前，去停用词的常见方法有查表法和基于文档频率的方法。查表法是预先建立好一个停用词表，然后通过查阅停用词表(stop-list)的方式过滤掉与文本内容本身没有多大关系的词条。基于文档频率的方法是通过统计每个词的文档频率，判断其是否超过总文档的某个百分比，若超过所设定的阈值，则当作停用词去掉。

8.3.1.3 文本表示

文本表示是将实际的文本内容转换为计算机内部的表示结构，是文本内容挖掘与分析的基础。在介绍具体文本表示之前先给出特征项和特征权重的概念。

定义 8.4 特征项(term)：文本表示模型中所用的基本语言单位，如字、词或词组。

定义 8.5 特征项权重(term weight)：表示该特征项对于文本内容的重要程度，权重越大的特征项越能代表该文本的内容。

最早文本表示模型用于信息检索领域，后来在文本分类、文本挖掘等领域也得到广泛的应用。当前，文本表示模型主要有如下几种。

1. 基于集合论的模型

基于集合论的模型(set theoretic-based models)包括：布尔模型、扩展布尔模型和基于模糊集的模型等。这里仅介绍典型的布尔模型(boolean model)。布尔模型建立在集合理论和布尔代数的基础上，是一个严格的基于查询特征项匹配的模型。该模型将文本表示为特征空间上的一个向量，向量中每个分量是二值变量。查询特征项之间通过逻辑运算符 AND、OR 和 NOT 相连，其与文本之间的匹配方式遵循布尔表达式的运算规则。若查询的特征项表达式与文本相匹配，则文本被检索出来，返回 1；否则文本不被检索出来，返回 0。

可见，布尔模型比较简单，容易理解，多被应用于商业检索系统，如 DIALOG、STAIRS 等。然而，把布尔模型用作文本表示具有一定的缺陷：基于严格的特征项匹配，不能提供近似或部分匹配；查询结果是 1 或 0，不能反映特征项对文本的重要程度，排序能力差；构造的查询决定了查询的结果的多少，同时对于一些复杂的用户需求也较难表达。

2. 基于代数论的模型

典型的基于代数论的模型(algebraic-based models)有：向量空间模型、潜在语义索引模型和神经网络模型等。这里介绍广泛应用的向量空间模型(Vector Space Model，VSM)。该模型是由 Cornell 大学的 G. Salton 等在 20 世纪 70 年代提出的，最早应用于信息检索领域，其原型系统为 SMART。

VSM 有两个基本假设：一个文本所属的类别仅与某些特征项在该文本中出现的词频有关，而与这些特征项在该文本中出现的位置或顺序无关；特征项与特征项之间是互异且相互独立的。VSM 的主要思想是：不考虑特征项在文本中出现的先后顺序，将文本表示为互异且相互独立的特征项的组合向量，以不同的特征项构造一个高维空间，每个特征项为该空间中的一维，文本则被表示为该空间中的一个向量。

具体地，对于一个文本 d，用 n 个互异的特征项表示为

$$(<d_1,w_1>,<d_2,w_2>,\cdots,<d_n,w_n>)$$

式中：d_i 表示该文本的特征项；w_i 为该特征项在该文本中的权重，最为经典的权重计算方法是 TF-IDF。查询也是一个文本，用 VSM 表示为

$$(<q_1,w'_1>,<q_2,w'_2>,\cdots,<q_n,w'_n>)$$

若要计算查询与文本之间的相似性，最直接简单的方法是计算它们之间的余弦值，公式如下

$$\mathrm{Sim}(q,d)=\cos\theta=\frac{\sum_{i=1}^{n}w'_i\times w_i}{\sqrt{\sum_{i=1}^{n}w'^{2}_i}\sqrt{\sum_{i=1}^{n}w_i^2}}$$

此外，还有其他各种计算该相似性的方法，如 Dice 系数、Jaccard 系数等。

可见，VSM 能有效克服布尔模型的缺陷，即能根据需要对查询中的特征项的重要性进行个性化赋值；支持部分匹配和近似匹配，结果可以排序；通过权重计算方法能有效提高系统的检索性能。然而，其前提假设之一是特征项之间的相互独立性与实际不符。实际特征项之间是存在一定关系的，如“信息”“技术”；另外也没有考虑特征项在类别间的分布情况。

3. 基于概率的模型

根据前面的分析，布尔模型和 VSM 都存在没有考虑特征项之间的关联性的这一缺陷。基于概率的模型（probabilistic-based models）则是利用特征项与特征项之间及特征项与文本之间的概率关系进行信息检索。常见的基于概率的统计模型有：经典概率模型、回归模型、推理网络模型等。

这里介绍经典概率模型，其主要思想是：根据用户的查询 q，可将文本分为与查询 q 相关的集合 R，与查询 q 不相关的集合 $\bar{R}$。在同一类文本中，各检索特征项具有相同或相近的分布；而属于不同类的文本中，检索特征项具有不同的分布。因此，可通过计算文本中所有检索特征项的分布，就可以判定该文本与检索的相关度。具体的相似度函数定义为

$$\mathrm{Sim}(q,d)=\frac{P(R\mid d)}{P(\bar{R}\mid d)}$$

式中：$P(R\mid d)$ 表示文本 d 和查询 q 相关的概率；$P(\bar{R}\mid d)$ 表示文本 d 和查询 q 不相关的概率。

该值越大说明文本 d 与查询 q 更相关。由于检索特征项的数量较大，为了简化计算过程，引入了不同的假设，最常见的模型有：二元独立模型（binary independent model）、二元一阶依赖模型（binary first order dependent model）和双泊松分布模型（two poisson independent model）。

总之，概率模型建立在数学基础上，理论性较强；文本可以按照相关概率递减的顺序进行排序，同时较好体现了文本信息的不确定性、模糊性；但过于依赖所处理的文本集的内容。

8.3.1.4 特征提取

上述过程得到的文本原始特征项可能处在一个高维空间中，将耗费较多的系统存储内存和处理时间。因此，如何从原始特征项中选择一些具有代表性的有效特征作为新的特征集，是解决“维度灾难”的有效途径。具体而言，文本的特征提取指从文本信息中抽取能够代表该类文本或文本信息内容的过程。文本特征提取可以实现以下目的：降低文本空间的维度和稀疏度，提高文本内容识别和分析的性能；所选择数量较少的特征项能更直接地反映文本主题，方便用户对文本内容的理解；能一定程度上去掉有干扰的噪声特征项，增强文本之间相似度的准

确性。

当前特征提取的方法可采用人工处理和计算机自动处理，其中人工处理是基于人的知识提取文本内容的代表性特征。然而，该方法具有一定的缺陷：人的工作量较大，且需要领域专家的参与；选择结果不便于进行动态调整，除非人工不断地进行该工作。另外一种常用的方法是利用计算机自动化处理，首先通过创造一个评价函数，对文本特征集中的每一个特征进行独立地评估，这样每个特征都获得一个评估分；然后对所有的特征按照其评估得分的大小进行排序；最后选取预定数目的最佳特征作为结果的特征子集。至于选取多少个最佳特征，以及采用什么评价函数都需要一个针对具体的问题通过实验来确定。

当前常见的特征提取评价函数有：文档频率(Document Frequency，DF)、互信息(Mutual Information，MI)、信息增益(Information Gain，IG)、χ^2 统计量(CHI-square)、交叉熵(Cross Entropy，CE)等，此处不再详述。

8.3.2 图像内容识别与分析

当前，图像比文本更能提供一些直观、丰富的信息，因而不良图像比不良文本更具有危害性。以图像处理与图像理解技术为基础的不良图像内容识别与分析是实现不良图像过滤的基础，是信息内容安全的一个重要组成部分。本节主要介绍不良图像的识别方法。

不良图像信息识别即是判断一幅图像中是否有含有不良的信息，这里的不良信息主要是指裸露的人体敏感部位。一般可通过图像的基本特征进行识别，典型的特征有肤色、纹理、形状、轮廓等。当前互联网上的不良图像一般是彩色图像，并且很多时候呈现大面积的裸露皮肤，因此本节主要以肤色特征为例，介绍如何通过肤色检测技术实现不良图像的识别，其中如何从不良图像中分割出肤色区域是肤色检测算法的前提。

8.3.2.1 数字图像表示

图像根据像素空间坐标和亮度的连续性可分为模拟图像和数字图像，其中模拟图像是通过物理量的强弱变化来记录图像上各点的亮度信息的图像，即是人眼见到的物理图像；而数字图像完全用数字来记录图像亮度信息。

通过空间采样、亮度量化过程可实现模拟图像到数字图像的转换过程，因此，数字图像可用空间坐标及对应的亮度值来表示，基本元素为像素。数字图像一般采用矩阵形式来存储，如对于一个灰度图像可表示为 $\boldsymbol{I}_{m\times n}=(I(i,j))_{m\times n}$，其中 $I(i,j)$ 表示坐标为 (i,j) 的像素点的灰度值，其取值范围为 0(全黑)～255(全白)；对于一个彩色图像 $\boldsymbol{C}_{m\times n}=(C(i,j))_{m\times n}$，每个像素 $C(i,j)$ 由 RGB 三原色构成，其中 RGB 是由灰度值来描述。

8.3.2.2 颜色度量

颜色是人的视觉系统对可见光的感知结果，感知到的颜色由光波的波长所决定。在图像数字化中，首先得考虑如何利用数字来描述颜色。国际照明委员会(International Commission on Illumination，ICI)定义了颜色固有且截然不同的三个要素，具体如下。

(1) 色调(hub)：又称色相，当人眼看一种或多种波长的光时所产生的色彩感觉，是使一种颜色区别于另一种颜色的要素，如红、橙、黄等。其和下面的饱和度统称为色度。

(2) 饱和度(saturation)：指颜色的纯度，表现颜色的深浅程度。一种特定的颜色可以看成是某种纯光谱色与白色的混色结果，光谱色的比例越大，则该颜色接近纯光谱色的程度就越高，颜色纯度就越高。例如，鲜红色的饱和度比粉红色的饱和度高。

（3）明度(brightness)：又称为亮度，是人眼对光源和物体表面的明暗程度的感觉，主要是由光线强弱决定的一种视觉经验。对于非彩色而言，其没有色调和饱和度的概念，只有亮度的差别。

8.3.2.3 颜色空间

颜色空间又称为颜色坐标系，在机器视觉中一般称为颜色模型，是颜色在三维空间中的排列方式。一般地，颜色可通过三个相对独立的属性来描述，这三个属性可看作是三维坐标系中的三个不同的维度，它们的综合作用构成了一个空间坐标，即为颜色空间。对于同一颜色而言，可从不同的角度去度量，即通过三个一组的不同属性所构成的不同颜色空间进行描述。常见的颜色空间如下。

1. 基础颜色空间

基础颜色空间主要有：RGB颜色空间、归一化RGB颜色空间和CIE-XYZ颜色空间。具体而言，RGB颜色空间是将红色(red)、绿色(green)和蓝色(blue)这三种基本颜色当作三维空间的三个维度，其中每个维度灰度值的取值范围为0～255。通过它们不同程度地叠加产生2563种颜色，几乎覆盖了人类视觉系统所能感知的颜色。然而，RGB颜色空间容易受到光照或阴影的影响，因此，人们通过将RGB值归一化形成归一化RGB颜色空间，从而消除部分光照对其的影响。

尽管RGB颜色空间在彩色光栅图像等显示器系统中得到广泛的应用，但是R、G、B三个分量之间相关度较高，且会将色调、饱和度和亮度混在一起，因此不适合对亮度多变的图像进行肤色检测。

2. 正交颜色空间

正交颜色空间利用人眼对色彩敏感度低于对亮度敏感度的特性，通过将RGB颜色空间表示的彩色图像变换到其他彩色空间，实现亮度和色度信号的分离，从而降低RGB颜色空间冗余，提高颜色信息的传输效率，典型的正交颜色空间有：YUV、YIQ、YC_bC_r等。

YUV颜色空间被欧洲电视系统所采用，用于PAL制式的电视系统，其中Y表示亮度，U和V代表的是色差，一般是与蓝色和红色的相对值。其与RGB颜色空间的转换关系如下

$$\begin{pmatrix} Y \\ U \\ V \end{pmatrix} = \begin{pmatrix} 0.299 & 0.587 & 0.114 \\ -0.147 & -0.289 & 0.436 \\ 0.615 & -0.515 & -0.100 \end{pmatrix} \begin{pmatrix} R \\ G \\ B \end{pmatrix}$$

YIQ颜色空间与YUV类似，被北美地区电视系统所采用，用于NTSC制式的电视系统，只不过I和Q分量是将U和V分量进行了33°的旋转。其与RGB颜色空间的转换关系如下

$$\begin{pmatrix} Y \\ U \\ V \end{pmatrix} = \begin{pmatrix} 0.299 & 0.587 & 0.114 \\ 0.596 & -0.275 & -0.321 \\ 0.212 & -0.523 & 0.311 \end{pmatrix} \begin{pmatrix} R \\ G \\ B \end{pmatrix}$$

YC_bC_r颜色空间是由YUV颜色空间派生的一种颜色空间，主要用于数字电视系统，其中C_b、C_r分别表示蓝色差信号和红色差信号。其与RGB颜色空间的转换关系如下

$$\begin{pmatrix} Y \\ C_b \\ C_r \end{pmatrix} = \begin{pmatrix} 0.299 & 0.587 & 0.114 \\ -0.1687 & -0.3313 & -0.5000 \\ 0.500 & -0.4187 & 0.0813 \end{pmatrix} \begin{pmatrix} R \\ G \\ B \end{pmatrix} + \begin{pmatrix} 0 \\ 128 \\ 128 \end{pmatrix}$$

3. 认知颜色空间

认知颜色空间用以解决基础颜色空间中不能从颜色RGB值中直观地知道颜色的色度和

亮度的问题，典型的认知颜色空间有：HIS、HSV、HSL 和 TSL 等。这里以 HSV 为例进行介绍，HSV 颜色空间是从人的视觉系统出发，用色调、饱和度和亮度来描述颜色。一般可用圆锥体进行可视化表达，色调被表示为绕圆锥中心轴的角度，饱和度被表示从圆锥的横截面的圆心到这个点的距离，明度被表示为从圆锥的横截面的圆心到顶点的距离。

若(r,g,b)代表 RGB 颜色空间中一个颜色的红、绿、蓝坐标，其取值为 0～1 的实数，令 $\max V=\max\{r,g,b\}$，$\min V=\min\{r,g,b\}$；(h,s,v)代表 HSV 空间中色调、饱和度和亮度，则从 RGB 到 HSV 的转换关系如下

$$h=\begin{cases}0^\circ, & \max V=\min V\\ 60^\circ\times\dfrac{g-b}{\max V-\min V}+0^\circ, & \max V=r \text{ and } g\geqslant b\\ 60^\circ\times\dfrac{g-b}{\max V-\min V}+360^\circ, & \max V=r \text{ and } g<b\\ 60^\circ\times\dfrac{b-r}{\max V-\min V}+120^\circ, & \max V=g\\ 60^\circ\times\dfrac{r-g}{\max V-\min V}+240^\circ, & \max V=b\end{cases}$$

$$s=\begin{cases}0, & \max V=0\\ \dfrac{\max V-\min V}{\max V}=1-\dfrac{\min V}{\max V}, & \text{其他}\end{cases}$$

$$v=\max V$$

反之，从 HSV 到 RGB 的转换可表示如下。

首先计算：

$$h_i=\left\lfloor\frac{h}{60}\right\rfloor \bmod 6, f=\frac{h}{60}-h_i,$$

$$p=v\times(1-s), q=v\times(1-f\times s), t=v\times(1-(1-f)\times s)$$

则在颜色空间 RGB 中的每个颜色(r,g,b)，可计算如下

$$(r,g,b)=\begin{cases}(v,t,p) & h_i=0\\ (q,v,p) & h_i=1\\ (p,v,t) & h_i=2\\ (p,q,v) & h_i=3\\ (t,p,v) & h_i=4\\ (v,p,q) & h_i=5\end{cases}$$

肤色一般在颜色空间中相当集中，但会受到照明和人种的影响。为了减少肤色受照明强度影响，通常将颜色空间从 RGB 转换到亮度和色度分离的某个空间中，如 YC_bC_r 或 HSV，然后放弃亮度分量。在双色差或色调饱和度平面上，不同人种的肤色变化不大，肤色的差异性更多的在于亮度而不是色度。

8.3.2.4 肤色模型

这里仅介绍静态肤色模型，当前静态肤色模型主要有：阈值法、参数化法和非参数化法。

1. 阈值法

该模型直接用数学表达式明确规定肤色的范围，是一种简单的肤色建模方法。检测时只

需要用二值查找表即可。该模型实现起来很简单，但要想取得好的检测效果，需要解决两个问题：如何选择合适的颜色空间；如何确定规则中的参数。

2. 参数化法

常用的利用参数化法进行肤色检测的模型有：高斯分布模型、椭圆边界法、聚群法等。这里以高斯分布模型为例介绍。

高斯分布模型是一种参数化模型，可分为单高斯模型(Single Gaussian Model，SGM)和高斯混合模型(Gaussian Mixture Models，GMM)。

(1) 单高斯模型采用椭圆高斯联合概率密度函数，公式为

$$p(\boldsymbol{x} \mid \text{skin}) = \frac{1}{2\pi \mid \boldsymbol{\Sigma} \mid^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right\}$$

式中：$\boldsymbol{x}$ 是像素颜色向量；均值向量 $\boldsymbol{\mu}$ 和协方差矩阵 $\boldsymbol{\Sigma}$ 是高斯分布参数，由训练样本估计：

$$\boldsymbol{\mu} = \frac{1}{n}\sum_{j=1}^{n} x_j, \boldsymbol{\Sigma} = \frac{1}{n-1}\sum_{j=1}^{n}(x_j-\boldsymbol{\mu})(x_j-\boldsymbol{\mu})^{\mathrm{T}}$$

上述条件概率 $p(\boldsymbol{x}|\text{skin})$可以直接用来衡量像素 $\boldsymbol{x}$ 属于肤色的可能性，也可以通过高斯分布参数计算输入像素 $\boldsymbol{x}$ 与均值 $\boldsymbol{\mu}$ 的马氏距离 $d=(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})$来表示像素与肤色模型的接近程度。

总体而言，若 $p(\boldsymbol{x}|\text{skin})\geqslant\alpha$ 或 $d\leqslant\beta$，则 $\boldsymbol{x}$ 为肤色，其中 α,β 为定义的阈值。

(2) 高斯混合模型是一个有效描述复杂形状分布的模型，它是由单高斯肤色模型经过一般化后得到的，即可表示为

$$p(\boldsymbol{x} \mid \text{skin}) = \sum_{i=1}^{k} w_i \cdot p_i(\boldsymbol{x} \mid \text{skin})$$

式中：k 为混合成分的个数；ω_i 是混合权重；$p(\boldsymbol{x}|\text{skin})$是高斯概率密度函数族，每个都有其自己的均值 μ_i 与协方差矩阵 $\boldsymbol{\Sigma}_i$，其参数可通过期望最大化 EM 算法得到。

对于其判断方法与单高斯模型一样，可通过条件概率 $p(\boldsymbol{x}|\text{skin})$，也可以通过像素与肤色模型之间的马氏距离进行计算。

3. 非参数化法

非参数化法比参数化法更适应于不同摄像机、不同环境下获取图像肤色建模。常用的非参数化法有：统计直方图模型、神经网络模型等。这里以统计直方图模型为例介绍。

统计直方图模型是给离散化的颜色空间中的每个格子赋予一个概率值，得到肤色概率图(Skin Probability Map，SPM)，利用 SPM 进行肤色检测。当前，常用的方法有正则化查表法和贝叶斯分类器。

(1) 正则化查表法：直接利用 SPM 作为肤色概率查找表。将输入像素的颜色向量经过与 SPM 相同的颜色空间变换和量化后所得到的向量作为查表的索引，查表得到的值是该输入像素属于肤色的概率。换句话说，这里的肤色概率即是肤色训练样本在这种颜色上所出现的相对频数：

$$p_{\text{skin}}(\boldsymbol{x}) = \frac{\text{Count}(\boldsymbol{x})}{\text{Norm}}$$

式中：$\text{Count}(\boldsymbol{x})$是训练样本中颜色空间向量 $\boldsymbol{x}$ 的像素个数；规则化参数 Norm 是训练样本中的像素个数的总数目。

(2) 贝叶斯分类器：正则化查表法中的 $p_{\text{skin}}(\boldsymbol{x})$只是估计条件概率 $p(\boldsymbol{x}|\text{skin})$，对肤色检

测更合适的度量应该是 $p(\text{skin}|\boldsymbol{x})$，所以计算如下

$$p(\text{skin}\mid \boldsymbol{x})=\frac{p(\boldsymbol{x}\mid \text{skin})p(\text{skin})}{p(\boldsymbol{x}\mid \text{skin})p(\text{skin})+p(\boldsymbol{x}\mid \neg\,\text{skin})p(\neg\,\text{skin})}$$

式中：$p(\boldsymbol{x}|\text{skin})$和 $p(\boldsymbol{x}|\neg\,\text{skin})$分别表示皮肤直方图中肤色和非肤色像素数目的比例。

若 $p(\boldsymbol{x}|\text{skin})$大于某阈值时，则有颜色 $\boldsymbol{x}$ 的像素被判断为皮肤像素。

8.4 信息内容控制和管理

在信息内容识别与分析的基础上，对不良的信息内容应进行过滤阻断，对私密信息应实现有效隐藏，对涉及版权的内容信息应加以保护。本节主要从信息过滤、信息隐藏及数字水印与版权保护三方面介绍有关信息内容控制与管理方面的相关技术。

8.4.1 信息过滤技术

当前，海量增长的互联网信息加剧了信息查找的难度，同时不法分子通过网络散布反动、暴力、黄色、邪教等信息内容严重扰乱了人们的健康生活和社会的稳定性。信息过滤一方面可以帮助人们从海量信息中找到所需的信息，有效地缓解信息过载的问题；另一方面作为一种信息内容控制技术，通过过滤各类不良信息，为用户提供一个健康的互联网环境提供了一种技术保障。作为信息过载和信息内容安全的一种有效解决方法，信息过滤得到业界的广泛关注。本节主要介绍信息内容过滤流程及相关技术。

1. 信息过滤概念

信息过滤(Information Filtering，IF)最早出现在 1982 年，ACM 主席 Peter Denning 在 *CACM* 期刊中指出不仅要研究电子文本的自动生成和扩散途径，同时也要研究对接收到的信息进行有效控制，即信息过滤。随后，在 1987 年，Malone 等提出社会过滤的概念，即基于以前用户对文本的标注来表示文本，通过交换信息自动识别具有共同兴趣的团体。目前，信息过滤没有统一的定义：Belkin 和 Croft 定义 IF 是用来描述将信息传递给有需要的用户的一系列过程的总称；Hanani 等定义 IF 指从动态信息流中将满足用户兴趣的信息挑选出来，用户的兴趣一般在较长一段时间内不会改变。IF 通常是在输入数据流中移除数据，而不是在输入数据流中找到数据。

一般地，IF 指根据用户的信息需求模型(user profile)，在动态的信息流(如 Web、E-mail)中，搜索用户感兴趣的信息，屏蔽其他无用的和不良的信息。用户需求模型是信息过滤的主要依据，以计算机可以理解的形式揭示用户的兴趣爱好。根据过滤的目的不同，IF 既可以用来收集有益的信息，也可以用来屏蔽有害的信息。这里更多的讨论后者，即以网络内容安全为出发点，为用户去除可能危害的信息，阻断其进一步传输。

信息过滤与信息检索(Information Retrieval，IR)密切相关，它们都是对用户某一特定的信息需求进行搜索，但其与信息检索则有所不同，从需求、信息源、目标及用户特点等方面进行比较，它们的差别如表 8.2 所示。

表 8.2 IR 和 IF 比较

	信息检索(IR)	信息过滤(IF)
需求表示	查询表达式	兴趣模型
需求变化	动态	静态

续表

	信息检索(IR)	信息过滤(IF)
信息源	静态	动态
目标	选择相关条目	过滤掉不相关的条目
了解用户	否	是
用户特点	短期使用	长期使用

在IR中，用户通常基于查询表达式进行信息检索，因而信息需求的变化率是比较快的，但是被检索的信息源的变化率是比较缓慢的，即IR是根据用户的特定信息需求，在静态的信息源中，检索与用户需求相关的信息条目，屏蔽无用的信息，用户的信息需求行为是一个短期行为。在IF中，用户通过构建用户需求模型来实现信息过滤，一般来说，用户的兴趣在一段时间内可认为变化不大，即用户的需求变化是静态的；但是数据源是将要到达的动态数据流，即IF是根据用户的信息需求，在动态信息源中搜索用户感兴趣的信息，屏蔽无用的信息，用户的信息需求行为是一个长期行为。可见，IR实现不需要了解用户的相关信息，适合多数用户短期使用，而IF需要了解用户的相关信息，得到用户的需求模型，适合少数用户长期使用。

除此之外，需要区分与IF密切相关的另外几个概念，如信息分类(Information Classification，IC)和信息抽取(Information Extraction，IE)。某些场合下人们所称的IF实际就是一个IC问题，即判断信息是否符合用户需求可看作是一个两类(是/否)的分类问题。一般而言，IC中的分类范畴通常不会变化，而IF的用户需求会动态调整。至于IE一般直接从自然语言文本中抽取事实信息，并以结构化的形式描述信息。比如，抽取恐怖事件的时间、地点、人物等字段。其不太关注相关性，而只关注相关的字段；而IF需要关注相关性。

信息过滤系统(Information Filtering System，IFS)是支持信息过滤过程而设计的自动化系统。一般地，IFS具有以下特点：系统处理对象是半结构化或非结构化数据，主要是文本信息；主要处理将要到达的数据流；用户需求过滤模板一般情况下是静态的；过滤意味着从即将到来的数据流中排除数据，而不是从数据流中发现数据。

2. 信息过滤系统的分类

根据不同的目的，信息过滤系统有不同的分类方式。

(1) 按网络数据捕获方式分类。8.2节将网络信息内容获取方式分为了主动信息内容获取和被动信息内容获取，其中主动信息内容获取主要通过搜索引擎技术实现网页信息的抓取；被动信息内容获取通过网络数据捕获实现。因此，根据网络信息内容的捕获方式不同，信息过滤系统可划分为主动数据搜集式过滤系统和被动数据获取式过滤系统。其中，主动数据搜集式过滤系统根据用户需求模型主动为用户搜集相关信息，然后将相关信息推送给用户；而被动数据获取式过滤系统不需要收集数据，通常应用于电子邮件过滤或新闻组。

(2) 按过滤操作的位置分类。按信息过滤系统所在的操作位置，可分为信息源过滤系统、信息过滤服务器过滤系统和用户端过滤系统。信息源过滤系统，又称剪辑服务(clipping service)系统，指用户将用户需求模型提交给一个信息提供者，由其为用户提供与过滤模型相匹配信息，如Dialog提供的Alert服务。信息过滤服务器过滤系统指信息提供者将信息提交给服务器，同时用户将用户需求模型提交给该服务器，服务器通过这些信息实现信息过滤，并将相关信息发给用户，如Stanford在1994年开发的SIFT系统。用户端系统过滤指对流经本

地的信息进行评估，过滤掉不相关的信息，如 Outlook 邮件过滤。

（3）按过滤的方法分类。按照过滤的方法，信息过滤系统可分为认知过滤系统、社会过滤系统、基于效用的过滤系统、基于智能代理的信息过滤等，其中认知过滤系统和社会过滤系统是两种常用的过滤系统。认知过滤系统，又称基于内容的信息过滤系统，Malone 等将其定义为："采用一种机制，描述信息内容和用户需求模型特征，然后用这些描述智能化地将信息与用户需求进行匹配。"社会过滤系统，又称基于协同过滤的信息过滤系统，指利用用户之间的相似的兴趣或相同的知识来构建用户需求模型，从而进行信息过滤和信息推荐。其与认知过滤系统的不同之处在于不是基于信息内容，而是基于其他用户的使用模式。除此之外，还有一些过滤系统：基于效用的过滤系统利用成本-效益评价和价格机制实现信息过滤；基于智能代理的信息过滤系统通过引入的智能代理自动修改用户需求模型并自动地进行相关的过滤操作。

（4）按获取用户知识的方式分类。按照获取用户知识的方式，信息过滤系统可分为显式知识获取过滤系统、隐式知识获取过滤系统和显隐混合知识获取过滤系统。显示知识获取过滤系统需要用户的直接参与，通过提问或填表等方式获取用户的信息需求，然而，由于语言表达问题，用户往往不能找到合适的关键词来表达真实的需求，从而影响过滤系统的准确度。隐式知识获取过滤系统是在不打扰用户的前提下，通过观测用户行为，如阅读文档时间、次数、上下文、行为（保存、删除、打印、单击等）等，然后采用机器学习方法来获取用户的信息需求。显隐混合知识获取过滤系统则综合使用显式知识获取过滤系统和隐式知识获取过滤系统。

（5）按信息过滤的工具分类。按照所使用的过滤工具，信息过滤系统可分为专门的过滤软件系统、网络应用程序过滤系统、防火墙过滤系统、代理服务器过滤系统、旁路方式过滤系统。专门的过滤软件系统是为过滤网络信息专门开发的软件。网络应用程序过滤系统指利用应用程序所具有的过滤功能，如 Web 浏览器、搜索引擎、电子邮件等。防火墙过滤系统通过设置 IP 地址和端口等实现进入数据包的过滤。代理服务器过滤系统是在客户机和服务器之间增加一个代理服务器，通过配置代理服务器实现信息进出控制。旁路方式过滤系统通过获取进出局域网的所有信息，通过相应的内容过滤处理，对网址和信息进行控制，与代理服务器过滤系统相比，这种方法不会对用户的网速造成影响。

3. 信息过滤系统的工作流程

信息过滤系统的一般模型如图 8.11 所示，主要包括 4 个基本的组件：数据分析组件、过滤组件、用户需求模型组件和学习组件。

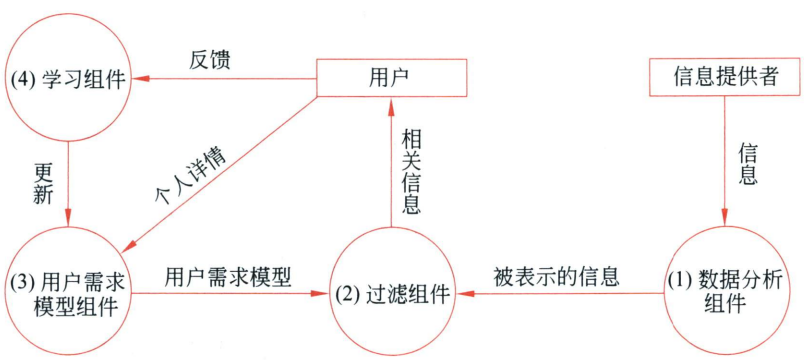

图 8.11　信息过滤系统一般模型

（1）数据分析组件。从信息提供者那里获取或收集信息（如文档、消息），对信息进行分析并抽取其中特征信息，以适当的数据形式（如空间向量）来表示，表示结果将被输入到过滤组

件中。

（2）过滤组件。过滤组件是信息过滤系统的核心，主要用来计算信息源与用户需求模型的相关度。相关度可以通过一个二值数据表示，即相关或不相关；也可以通过对一个文本评分，一般采用概率表示。过滤组件可应用于一条单独的信息，如一封电子邮件；也可以应用于一组信息，如文档集合。然后将过滤的结果发送给用户，用户是信息相关性的最终决策者，其决策的结果可反馈给学习组件。当前，过滤组件采取相似性度量方法很大程度上取决于文本表示模型，常见的文本表示模型，如基于集合论的模型、基于代数论的模型和基于概率的模型。除此之外，一些基于机器学习的方法，如支持向量机（SVM）、最近邻分类法、基于贝叶斯的方法等也可用于文本表示。当前，典型的文本信息与用户需求模型的匹配技术包括：基于关键字匹配、余弦相似性度量、基于范例的推理、朴素贝叶斯分类器、最近邻参照分类、一些典型的分类算法（如神经网络、决策树、归纳规则和贝叶斯网络）等。

（3）用户需求模型组件。用户需求模型组件通过显式或隐式地搜集用户的信息生成用户需求模型，并将用户需求模型传递给过滤组件。因为过滤的主要目的是根据用户需求模型来判断信息与用户需求的相关度，因此如何有效地描述用户需求模型是信息过滤系统要解决的一个关键问题。若用户需求模型不准确，将会直接导致过滤结果的偏差和错误。用户模型可分成4类，具体如图8.12所示。

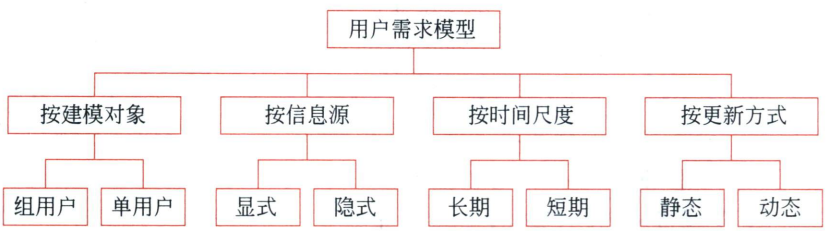

图 8.12　用户需求模型分类

此外，当前常见的用户需求模型还有：用户手工创建用户模型、系统创建用户模型、用户和系统相结合的模型、基于人工神经网络学习用户模型、基于用户版型导出用户模型和基于规则的用户模型等。

（4）学习组件。考虑到建立和更改用户需求模型的困难性，信息过滤系统中通过增加一个学习组件能更好地提供过滤模型，提高过滤系统性能；否则，不精确的用户模型将影响过滤结果。学习组件通过发现用户兴趣变化，强化、弱化或取消现存有关用户的知识来更新用户模型。

当前，常见的学习方法包括：观察学习、反馈学习和用户训练学习等。观察学习指将导致动作（保留或抛弃）发生的条件记录下来，当新的情况发生时，就与已经记录下来的情况相比较，从而决定是否采取某种行动。反馈学习指通过用户直接或间接地提供反馈，来预测新的信息的相关度。用户训练学习指通过模拟某种情景，用户对系统做出相应的操作来构建一个情景数据库，当要采取什么行动时，系统就使用所构建的情景数据库进行推断。

4. 信息过滤系统的关键技术

在前面介绍了信息过滤系统的基本工作流程，然而，由于组件之间是相互关联的，因而单独描述每个部件的实现技术缺乏可操作性。这里以两种信息过滤系统为例进行介绍。

（1）基于统计学理论的信息过滤系统。在该系统中，用户需求模型和信息均可用向量空间模型表示，过滤组件采用统计算法计算用户需求模型与信息的相似性，最常见的可采用夹角

余弦计算。若要评估大量的信息，则可对计算得到的相似性结果进行排序。学习组件要求用户决定过滤结果是否相关得到相应反馈，通过采用反馈学习方式来更新用户需求模型，主要更新用户的特征项及其权重。

(2) 基于知识的过滤系统。在该系统中，主要基于知识论、本体论等中的相关知识，如语义网、神经网络、产品规则等，实现信息过滤，主要包括：基于规则的过滤系统、基于语义网络的过滤系统、基于神经网络的过滤系统和进化的基于遗传学算法的过滤系统等。

基于规则的过滤系统中用户需求模型和过滤组件都是由一组规则组成。若规则被满足，则系统能够运行，规则命令过滤组件将信息滤掉或保留下来。若新到来的信息是半结构化的，则将规则应用于信息的结构化部分；若新到来的信息是非结构化的，则必须对非结构化数据进行推导。然而，基于规则的过滤系统中的规则随着时间的增长，需要动态进行更新。基于语义网络的过滤系统通过将语义信息引入用户需求模型和过滤组件中，可提高过滤的准确率。

5. 信息过滤系统的评估指标

目前，没有统一评估信息过滤系统有效性的标准。这是因为对过滤系统而言，不仅包括信息内容，还包括用户的兴趣、内涵、用户理解等不同的因素，从而造成对过滤结果评价的不同。常用的评估指标包括查准率和查全率。其中查准率指所有过滤出的信息中，与实际过滤判断的结果一致的信息所占的比例；而查全率指能够将实际判断应该过滤出来的所有信息均识别出来。

对于集合大小为 N 的信息集合，实际与用户需求相关的集合大小为 M。通过过滤组件进行过滤，若已经通过过滤的 n 条相关信息中，有 m 条与用户需求是相关的，即是符合用户需求模型的，则有 $n-m$ 条是与用户需求不相关的，具体如表 8.3 所示。

表 8.3　查准率和查全率计算表

	相　关	不 相 关	总　数
已通过过滤	m	$n-m$	n
未通过过滤	$M-m$	$N-n-M+m$	$N-n$
	M	$N-M$	N

查准率和查全率公式如下

$$\text{查准率(precision)}：p=\frac{\text{已通过过滤中相关信息集合大小}}{\text{已通过过滤集合大小}}=\frac{m}{n}$$

$$\text{查全率(recall)}：r=\frac{\text{已通过过滤中相关信息集合大小}}{\text{信息源中实际相关的信息集合大小}}=\frac{m}{M}$$

除此之外，信息过滤系统的其他衡量指标还有响应时间、拒绝率、效用、平均精度等。

8.4.2　信息隐藏技术

当前，信息内容具有数字化、多样性、易复制、易分发、交互性等特点极大地方便了对信息内容的操作；同时开放的互联网环境为信息内容传播提供了有效的途径，有效地促进了信息交换与信息共享。然而，这种便捷的操作和传播方式在便利人们生活和工作的同时，也给敏感信息保护和知识产权保护带来了极大的挑战，如非法用户对信息内容的窃取、泄密和篡改，以及

在未经授权的情况下复制和传播有版权的信息内容等。可见，如何实现信息内容的安全传输及版权保护已成为信息内容安全的一个重要部分。为了有效应对这种挑战，信息隐藏(Information Hiding，IH)和数字水印(digital watermark)技术应运而生。

本节首先介绍信息隐藏技术的基本概念，重点阐述其与密码学之间的关系；然后介绍信息隐藏技术的原理、分类、特征及应用场景；最后介绍信息隐藏技术的重要分支数字水印的相关理论。

1. 信息隐藏技术的基本概念

信息隐藏技术指将某一机密信息秘密地隐藏于公开传输的媒介信息中，使人难以察觉到机密信息的存在，然后通过公开媒介信息的传输来传递隐藏的信息。其中公开媒介信息既可以是数字媒体信息(如图像、视频、音频)，也可以是一般性文本。由于含有隐藏信息的媒介信息是公开发布的，并且攻击者难以从公开信息中检测隐藏信息是否存在，更难以截获隐藏的信息，从而在一定程度上保障信息的安全传输。

密码学和信息隐藏是信息安全领域两大重要的分支，但两者之间有些差别。

(1) 信息传输方式不同：密码学中的加密技术主要研究如何通过数学变换将机密信息编码成不可识别的密文信息。然而，加密后的信息更容易引起攻击者的注意，攻击者可通过截获密文，对其进行破译或将密文进行破坏后发送，从而影响私密信息的安全性。对于信息隐藏而言，其目标是要使得攻击者难以从公开的媒介信息中检测是否有私密信息的存在，难以截获机密信息，从而能保证机密信息的安全。

(2) 信息保护的形式和时间不同：加密技术通过使攻击者无法从密文中获取机密信息而达到信息安全保护的目的，因此无法解决网络传输中的版权保护问题。一方面，加密技术将信息内容编码成无法理解的密文形式，妨碍了信息内容的传播和交流；另一方面，加密技术针对的是传输过程中或其他的加密状态的信息安全问题，一旦信息内容被解密后，其对信息内容的保护也就消失，从而无法防止信息内容的非法复制和传播，也就丧失了对信息内容数字版权的保护。

尽管加密技术和信息隐藏存在如上不同，但是加密技术和信息隐藏两者都是实现信息安全的重要手段，两者并不矛盾。在有些情况下，信息隐藏技术会用到加密技术，通过先加密机密信息，然后把类似乱码的机密信息用嵌入算法隐藏到公开媒介中，可实现更好的安全性。

2. 信息隐藏技术模型

信息之所以能够隐藏在公开媒介信息中，主要是因为：一方面，多媒体信息本身存在较大的冗余性。从信息论角度看，未压缩的多媒体信息的编码效率是很低的，所以将某些信息嵌入多媒体信息中进行秘密传送是可行的，并不会影响多媒体本身的传输和使用。另一方面，人眼或人耳本身的生理局限性对某些信息不敏感。利用人的这些特点，可以较好地将信息隐藏而不被察觉。

在介绍信息隐藏技术模型之前，先给出一些专业术语：在信息隐藏技术中，被隐藏的信息称为隐秘信息；用于嵌入隐秘信息的媒介信息称为载体；嵌入隐秘信息之后的载体称为伪装介质；将隐秘信息嵌入进载体得到伪装介质的过程称为嵌入过程，对应的算法称为嵌入算法；通过处理伪装介质得到隐秘信息的过程称为提取过程，对应的算法称为提取算法；嵌入过程和提取过程中所使用的密钥分别称为嵌入密钥和提取密钥，由密钥分发中心来提供。

典型的信息隐藏技术模型如图 8.13 所示，主要由嵌入算法和提取算法构成。

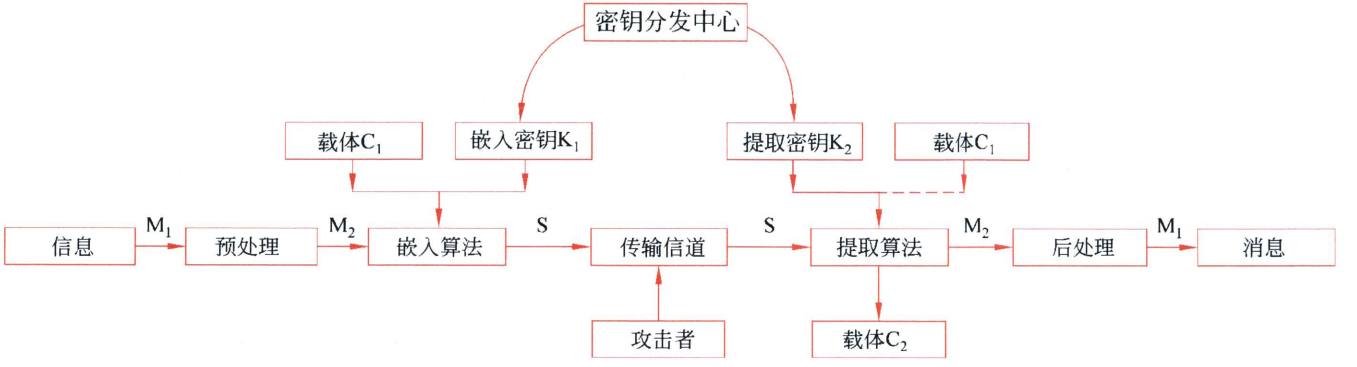

图 8.13　信息隐藏技术模型

隐秘信息 M_1 在加密、数据压缩或其他预处理操作之后得到中间信息 M_2；然后在嵌入算法和嵌入密钥 K_1 的作用下，将 M_2 嵌入载体 C_1 中，得到嵌入隐秘信息的伪装介质 S；S 通过公共传输信道发送给接收方，攻击者可在传输信道处窃听或截获传输的信息；接收方在收到传输过来的伪装介质 S 之后，利用提取算法和提取密钥 K_2，可能也需要使用载体 C_1，从 S 中提取中间消息 M_2 和得到载体 C_2；在后处理阶段利用先前预处理的逆过程将 M_2 恢复成隐秘信息 M_1。为了能有效提取所嵌入的信息，通信双方需要事先协商好所采用的算法和密钥。若嵌入时密钥 K_1 与提取时密钥 K_2 相等，则为对称 IH 算法；反之为非对称 IH 算法。在提取过程中，可使用原始载体 C_1，也可以不使用载体 C_1，若提取时不使用原始载体 C_1，则称为盲检测；反之则称为非盲检测。若原始载体 C_1 与恢复的载体 C_2 相等，则为无损 IH 模型，又称可逆 IH 模型；反之为有损 IH 模型。

3. 信息隐藏技术分类

按照不同的标准，信息隐藏技术有不同的分类方法，最典型的信息隐藏技术分类如图 8.14 所示。

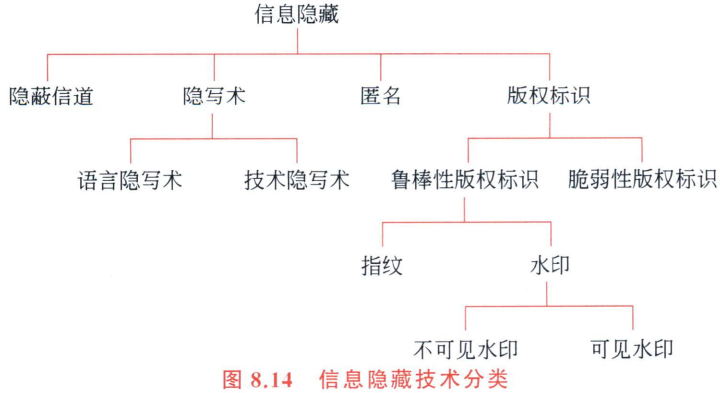

图 8.14 信息隐藏技术分类

（1）隐蔽信道(covert channels)。隐蔽信道指允许进程以危害系统安全策略的方式传输信息的通信信道。目前，对其有多种不同的定义方式，较为常见的是 Tsai 等的定义：给定一个强制安全策略 M 及其在一个操作系统中的介绍 $I(M)$，则 $I(M)$ 中的两个主体 $I(S_h)$ 和 $I(S_l)$ 之间的通信是隐蔽的，当且仅当模型 M 中的对应主体 S_h 和 S_l 之间的任何通信都是非法的。可以看出，隐蔽通道只与系统的强制访问策略模型相关，并且广泛存在于部署了强制访问控制机制的安全操作系统、安全网络和安全数据中。

（2）隐写术(steganography)。隐写术是信息隐藏技术的重要分支之一，主要研究如何隐藏实际存在的隐秘信息。一般地，隐写术可分为语言隐写术和技术隐写术。语言隐写术是利用语言本身的特性，将隐秘信息隐藏在文本中，如藏头诗；技术隐写术是将隐秘信息进行技术处理后隐藏到载体中，使得隐秘信息不易被察觉，同时也不影响载体信息的使用，如使用不可见墨水给报纸上的某些字母加上标记向间谍发送信息等。

（3）匿名(anonymity)。匿名是通过隐藏信息通信的主体，即信息的发送者和接收者，来达到信息隐藏。不同情况下的应用决定了匿名的对象，是匿名发送者或是匿名接收者，还是两者都要匿名。例如，Web 应用比较强调接收者的匿名性，而电子邮件用户则更关心发送者的匿名性。

（4）版权标识(copyright marking)。版权标识是实现信息内容产品版权保护的一种有效技术，即将证明版权所有者的信息嵌入到信息内容产品中以达到版权保护的目的，可分为鲁棒性版权标

识和脆弱性版权标识。鲁棒性版权标识主要用来在信息内容产品中标识版权信息，要求能抵御一般的信息处理，如滤波、缩放、旋转、裁剪和有失真压缩等，以及一些恶意的攻击；脆弱性版权标识嵌入信息量和提取阈值都很小，很小的变化就足以破坏版权标识信息，一般用来对信息内容产品做真伪鉴别及完整性校验。根据标识内容和采用的技术，鲁棒性版权标识可分为指纹技术和水印技术。指纹技术是为了避免未经授权的复制和发行，出版商可将不同序列号作为不同指纹嵌入信息内容产品的合法备份中，一旦发现未经授权的非法备份，可通过恢复指纹确定其来源；水印技术是将特制的标记，利用数字内嵌的方法嵌入信息内容产品中，用来证明作者对其作品的所有权。水印根据外观可分为不可见水印和可见水印。

除此之外，信息隐藏技术按照其他的标准，还有以下不同的分类方式。

(1) 根据信息隐藏技术的载体类型分类：文本信息隐藏技术、图像信息隐藏技术、音频信息隐藏技术、视频信息隐藏技术等。

(2) 根据嵌入域分类：时域(空域)信息隐藏技术和频域(变换域)信息隐藏技术。时域信息隐藏技术是直接用待隐藏的信息替换载体信息中的冗余部分。频域信息隐藏技术是将待隐藏的信息嵌入到载体的一个变换空间(如频域)中，具体内容将在后面进行介绍。

4. 信息隐藏技术特征

根据信息隐藏技术的目的和技术要求，信息隐藏技术具有如下特征。

(1) 鲁棒性(robustness)：指载体不因某种攻击或改动而导致隐秘信息丢失的能力，是衡量信息隐藏技术性能的重要指标。

(2) 不可检测性(undetectability)：要求嵌入隐秘信息的载体与原始载体之间具有一致性。由于信息隐藏技术主要通过伪装的方式提高信息的安全性，因此在嵌入隐秘信息后，要求人们的感觉器官是不可感知的，同时使用统计方法也无法检测到载体上嵌入的隐秘信息。

(3) 嵌入容量(capacity)：在单位时间内或在一个载体内最多嵌入信息的比特数。在满足嵌入隐秘信息到载体的质量前提下，应尽可能提高嵌入容量。这样一方面可以嵌入尽量多的隐秘信息；另一方面可采用纠错编码等技术降低提起信息的误码率。

(4) 透明性(invisibility)：经过一系列隐藏处理，目标数据在质量上没有明显降低，但隐藏的数据却无法人为地看见或听见。

(5) 安全性(security)：嵌入算法具有抗攻击能力，即它能够承受一定程度的攻击，但隐秘信息不会被破坏。

(6) 自恢复性(self-repairability)：在嵌入隐秘信息的载体遭受破坏的情况下，能够从留下的片段数据中恢复出隐秘信息，且恢复过程中不需要原始载体的能力。

(7) 对称性(symmetry)：嵌入过程和提取过程具有对称性，以减少存取难度。

在这些特点中，鲁棒性、不可检测性和嵌入容量是信息隐藏技术最主要的三个属性，它们之间相互制约。除此之外，信息隐藏技术还有一些其他的特征，如可纠错性、通用性等。

5. 信息隐藏技术的主要应用

当前，信息隐藏技术在不同领域得到应用，下面介绍一些典型的应用。

(1) 隐秘通信。信息隐藏技术最早主要用于实现隐秘信息的安全传输。由于嵌入隐秘信息的载体从表面上看与普通的公开媒介信息没有差别，使得攻击者难以觉察隐秘信息的存在。只有合法的接收者才知道隐秘信息的存在，并且能从伪装介质中恢复出隐秘信息。目前，信息隐藏技术除了可用于军事用途，同时也被应用于个人、商业机密信息保护、电子商务中的数据传输、网络金融交易中重要信息的传递等。

（2）版权保护。当前，信息内容产品具有的数字化、易窃取、易篡改和易复制等特点使得版权问题在当前开放的互联网环境下尤为突出。通过信息隐藏技术分支中的数字水印技术能有效解决信息内容产品的版权保护问题。数字水印以不可检测的方式嵌入到载体中，在不损害原信息内容产品的使用价值的前提下，同时达到了版权保护的目的。此外，通过指纹版权标识能有效追查盗版来源。即信息内容产品拥有者向授权使用用户所提供的信息内容产品中嵌入不同且唯一序列号的指纹信息，同时维护授权的信息内容产品备份中指纹与使用用户身份之间的对应关系数据库。一旦出现未经授权的备份，则信息内容产品拥有者可通过所维护的对应关系数据库找到提供非法备份的来源，即可实现有效追查盗版的目的。

（3）认证和篡改检测。通过在信息内容产品中嵌入数字水印信息，能有效实现对信息内容产品所有权的认证。此外，通过使用脆弱性版权标识能够有效地检测信息内容的真实性及完整性。目前，这项技术已经广泛应用于公安、法院、商业、交通等领域，用来判断犯罪记录、现场事故照片是否被篡改、伪造或特殊处理过。

（4）票据防伪。高精度扫描机、打印机、复印机等产品的出现，使得货币、支票及其他票据的伪造变得更加容易。通过在票据中嵌入隐藏的水印信息，为各种票据提供不可见的认证标识，从而大大增加了伪造的难度，可有效保证票据的真实性。

（5）数据的不可抵赖性。在电子商务交易中，交易的双方均可能抵赖自己所做过的行为，或否认曾经接收对方的信息。此时，可通过信息隐藏技术给交易过程中的信息嵌入各自的特征标识，并且这种特征标识是不可去除的，从而能有效防止抵赖行为的发生。

（6）信息备注。在有些情况下，需要备注某些信息的有关情况，如数据采集时间、地点和采集人信息。若直接将这些私密信息标注在原始文件上，将对用户的个人隐私造成极大的威胁。可利用信息备注有效解决该问题，通过将要备注的信息秘密地嵌入媒介信息中，只有通过特殊的提取算法或密钥才能读取，从而有效地解决私密信息备注问题。

8.4.3 数字水印与版权保护

在信息隐藏技术中，隐写术和数字水印（digital watermarking）是两个主要的分支，其中隐写术主要实现隐秘通信；数字水印技术作为信息隐藏技术的重要分支，主要用来实现版权保护、真伪鉴别、认证和完整性检测等。作为数字版权保护的主要技术，本节主要介绍数字水印的概念、特征、框架、分类及相关算法等。

8.4.3.1 数字水印的基本概念

当前，数字水印没有统一的定义，一般认为：数字水印技术指把标识版权的数字信息嵌入多媒体数据中（如图像、音频、视频等），以达到数字产品真伪鉴别、版权的所有者证明等功能。这些信息可以是用户序列号、公司标识等版权标识，并且永久地镶嵌在数字多媒体中，只有通过专门的检测器或阅读器才能提取水印信息，从而确定版权归属问题。

8.4.3.2 数字水印的特征

数字水印技术是信息隐藏技术的重要分支，除了具备前面所述的信息隐藏技术的一般特点外，还有其固有特点，主要如下。

（1）鲁棒性：这是数字水印最重要的一个特征。具体而言，鲁棒性指含有数字水印的信息内容产品经过几何变换、压缩、加噪、滤波等攻击后，水印信息仍然可以正确地检测并提取

出来。

(2) 不可感知性：主要指不可见水印从人类视觉上和采用统计方法也无法检测或提取数字水印信息。

(3) 安全性：即使攻击者知道数字水印算法的情况下，也无法实现未经授权的数字水印嵌入、检测/提取和未经授权的数字水印删除等操作。

(4) 可证明性：含有数字水印的信息内容产品在遭受到盗版、侵权或泄露等行为的时候，数字水印技术可以为用户提供安全、可靠且毫无争议的版权证明。

(5) 嵌入容量：对于数字水印系统而言，其嵌入容量要求相对较小，而隐写术则通常要求较大的嵌入容量。这是因为对于数字水印算法，嵌入的信息量越大，越可能降低数字水印的鲁棒性。在实际中，需要平衡嵌入容量和鲁棒性之间的关系。

8.4.3.3 数字水印系统框架

一般地，数字水印系统框架可表式化为一个九元组：$(M, X, W, K, G, E_m, A, D, E_x)$，其中：$M$ 表示原始信息 m 的集合；X 表示所有要保护的信息内容产品 x 的集合；W 表示所有可能数字水印信号 w 的集合；K 表示数字水印密钥集合；G、E_m、A、D、E_x 分别表示数字水印的生成、嵌入、攻击、检测和提取算法。一个完整的数字水印系统框架应由五部分组成：数字水印生成算法、数字水印嵌入算法、数字水印攻击算法、数字水印检测算法和数字水印提取算法，具体如图 8.15 所示。

1. 数字水印生成算法

数字水印生成算法 G 的主要思想是在密钥集合 K 的控制下，由原始信息 m 生成适合嵌入信息内容产品 x 中的待嵌入数字水印 w 的过程，是数字水印处理的基础。G 可形式化表示为

$$G: M \times X \times K \rightarrow W, w = G(m, x, K)$$

式中，原始信息 m 主要类型有：文本信息、声音信号、二值图像、灰度图像、彩色图像和无特定含义的序列。

数字水印生成算法 G 应保证数字水印信息的唯一性和有效性。为了提高数字水印系统的鲁棒性和安全性，通常不是直接嵌入原始信息，而是通过某种方法生成适合嵌入的数字水印 w。常见的数字水印生成算法有：伪随机水印生成、扩频水印生成、混沌水印生成、纠错编码水印生成、基于分解的水印生成、基于变换的水印生成、多分辨率水印生成和自适应水印生成方法等。

2. 数字水印嵌入算法

数字水印嵌入算法 E_m 指将生成的数字水印按照一定的规则嵌入信息内容产品 x 中，生成嵌入数字水印的信息内容产品 x^w，可形式化表示为

$$E_m: X \times W \rightarrow X, x^w = E_m(x, w)$$

式中：x 表示信息内容产品；x^w 表示嵌入数字水印的信息内容产品。为了提高安全性，有时候在 E_m 中使用嵌入密钥进行水印嵌入。

常见的数字水印嵌入规则有：加性规则、乘法规则、替换规则、量化规则、基于关系嵌入规则、基于统计特性嵌入规则等。例如，加性规则 $x^w = x + \alpha w$；乘法规则 $x^w = x + \alpha x w$，其中 α 为数字水印强度，用以调节数字水印不可感知性和数字水印鲁棒性。

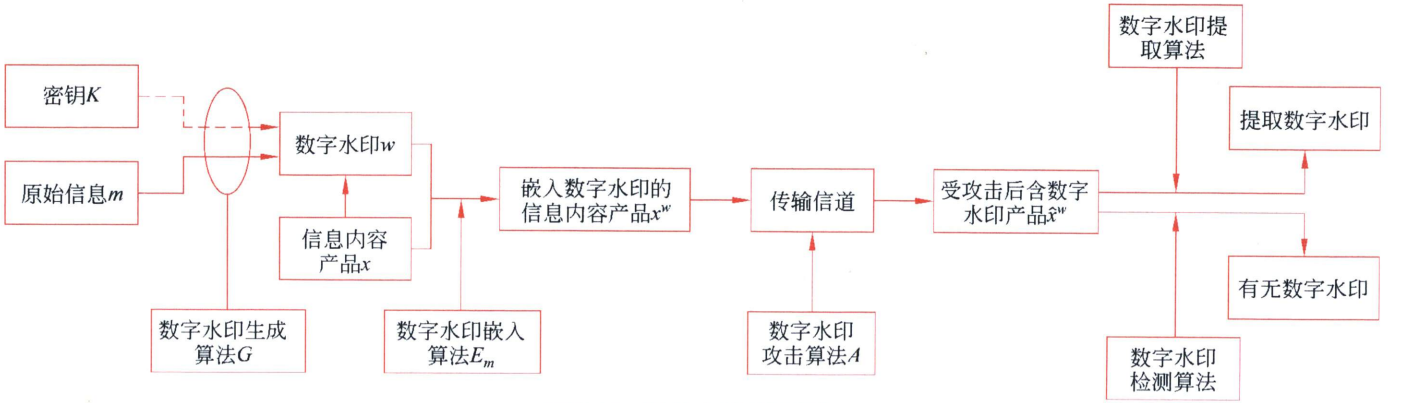

图 8.15　数字水印系统框架

3. 数字水印攻击算法

与密码技术类似，数字水印技术在实际应用中也会遭受各种各样的攻击。攻击者主要通过对含有数字水印的信息内容产品进行常规或恶意的处理，使得数字水印系统的检测工具无法正确地恢复数字水印信号，或者不能检测到水印信号的存在。数字水印攻击算法可表示为

$$A: X \times K \rightarrow X, \hat{x}^w = A(x^w, K')$$

式中：K'是攻击者伪造的密钥；$\hat{x}^w$ 是被攻击后含数字水印的产品。

当前，不同的研究人员对数字水印攻击进行了不同的分类。例如，Craver 等将攻击方法分为鲁棒性攻击(robustness attack)、表达攻击(presentation attack)、解释攻击(interpretation attack)和合法攻击(legal attack)；Hartung 等将攻击方法分为简单攻击(simple attack)、禁止提取攻击(detection-disabling attack)、混淆攻击(ambiguity attack)和去除攻击(remove attack)；Voloshynovskiy 等将攻击分为去除攻击(removal attack)、几何攻击(geometrical attack)、密码攻击(cryptographic attack)和协议攻击(protocol attack)。除此之外，还有各种其他类型的划分，这里就不再赘述。

4. 数字水印检测算法和提取算法

数字水印检测算法 D 是根据检测密钥通过一定的算法判断出信息内容产品 $\hat{x}^w$ 中是否含有数字水印信息。数字水印提取算法 E_x 是在确定信息内容产品 $\hat{x}^w$ 含有数字水印信息的情况下，利用提取密钥，根据数字水印嵌入算法 E_m 的逆过程 E_x 提取信息内容产品 $\hat{x}^w$ 中的数字水印信息 $\hat{w}$，即数字水印提取算法 E_x 可看作是数字水印嵌入算法 E_m 的逆过程。

目前，数字水印检测算法主要有基于相关性的数字水印检测算法和基于统计决策理论的数字水印检测算法，其中基于相关性数字水印检测算法得到了广泛应用。其基本思想是通过计算受到攻击后且嵌入数字水印的信息内容产品 $\hat{x}^w$ 与原始信息内容产品 x 之间的相关性，若相关性超过了给定的阈值，则可判断信息内容产品 $\hat{x}^w$ 中已经嵌入数字水印信息 w；反之，则没有嵌入数字水印信息。

8.4.3.4 数字水印的分类

按照不同的标准，数字水印有不同的分类方式，主要如下。

(1) 按数字水印所附载信息内容类型分类。根据数字水印所依附的载体不同，可将数字水印划分为文本数字水印、图像数字水印、音频数字水印、视频数字水印等。

(2) 按数字水印的外观分类。根据数字水印的外观可见性，可将数字水印划分为可见数字水印和不可见数字水印。可见数字水印的目的在于明确标识版权，防止非法使用。其不会影响信息内容产品的使用，但降低了信息内容产品的质量。不可见数字水印从信息内容产品表面是察觉不到的，当发生版权纠纷时，版权所有者可通过专门的检测器从中提取标识，从而证明信息内容产品的版权，是目前应用比较广泛的数字水印。

(3) 按数字水印的内容分类。根据数字水印的内容，可将数字水印分为有意义数字水印和无意义数字水印。有意义数字水印指数字水印本身也是某个数字图像，如商标图形或数字音频片段的编码；无意义数字水印则使用一个随机序列来表示，无法从主观视觉上判断去表达的意思。

(4) 按数字水印的特性分类。按数字水印特性，可将数字水印划分为鲁棒性数字水印和脆弱性数字水印。鲁棒性数字水印主要用于标识信息内容产品的版权归属，如版权信息、所有者信息等，其要求嵌入的数字水印能抵抗多种有意或无意攻击；脆弱性数字水印与鲁棒性数字

水印刚好相反，其对内容的修改非常敏感，主要用于信息内容完整性保护。

（5）按数字水印的检测/提取过程分类。根据数字水印的检测/提取过程，可将数字水印划分为非盲水印、半盲水印和盲水印。非盲水印指在检测和提取时需要原始附载信息内容和原始数字水印的参与；半盲水印指在检测和提取过程中不需要原始附载信息内容，但需要原始数字水印；盲水印指数字水印检测和提取过程中既不需要原始附载信息内容参与，也不需要原始数字水印。

（6）按数字水印隐藏的位置分类。根据数字水印的隐藏位置，可将数字水印划分为时域（空域）数字水印、频域（变换域）数字水印。时域（空域）数字水印是通过在时/空域修改信号样本达到隐藏数字水印的目的，主要有最低有效位（Least Significant Bit，LSB）方法、Patchwork方法、纹理块映射编码方法等。频域（变换域）数字水印指通过将信号样本经过某种变换如离散小波变换（Discrete Wavelet Transform，DWT）、离散傅里叶变换（Discrete Flourier Transform，DFT）、离散余弦变换（Discrete Cosine Transform，DCT）或奇异值分解（Singular Value Decomposition，SVD）变换后通过改变其变换系数达到嵌入数字水印的目的。

（7）按数字水印算法的可逆性分类。根据数字水印检测和提取后是否可以完全恢复原始信息，可将数字水印分为非可逆数字水印和可逆数字水印。

（8）按数字水印算法的用途分类。根据数字水印的用途，可将数字水印划分为版权保护水印、票据防伪水印、认证/篡改提示水印和隐藏标识水印等。

8.4.3.5 数字水印在数字版权保护中的应用

数字水印技术为数字版权保护提供了一种解决方案。在开放的互联网环境中，要构建一个完整的信息内容产品的保护系统，除了制定数字水印的嵌入和检测/提取过程的实施方案外，还需要采取一套完整的体系和协议，规定网上利益各方在信息内容产品交易时，必须遵守一套认可的协议。

1. 数字版权保护概念

数字版权保护技术（Digital Rights Management，DRM）就是对各类数字内容知识的知识产权进行保护的一系列软硬件技术，用以保证数字内容在整个生命周期内的合法使用，平衡数字内容价值链中各个角色的利益和需求，促进整个数字化市场的发展和信息的合法传播。DRM贯穿于数字内容的产生、分发、销售、使用的整个内容流通过程，涉及整个数字内容价值链，如图8.16所示。

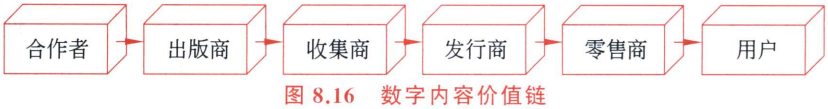

图8.16 数字内容价值链

对数字内容的版权保护，必须根据所保护的数字内容特征，按照相应的商业模式和现行的法律体系进行。数字版权保护技术和商业模式、法律基础三者相辅相成，构成整个数字版权保护体系。这里主要介绍数字版权保护技术。在DRM系统中，数字水印技术可实现元数据保护、发现盗版后取证或跟踪、篡改提示与完整性保护、许可证信息保护和数据注解和访问控制等功能。

2. 基于数字水印的数字版权保护系统

一个比较有影响的安全数字水印体系是欧盟委员会DGIII计划制定的网络数字产品的知识版权保护（Intellectual Property Rights，IPR）认证和保护体系标准IMPRIMATUR。这里仅考虑数字产品原创者、销售商到购买用户之间的利益关系。在此基础上，介绍一种简化的基

于数字水印的数字产品的版权保护系统，如图 8.17 所示。

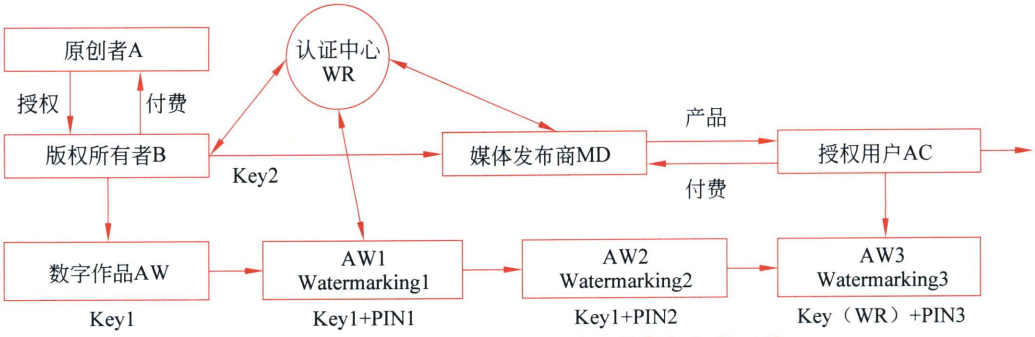

图 8.17 基于数字水印的数字产品的版权保护系统

在该系统中，A 为数字产品的原创者，WR 为版权登记认证中心。A 在完成数字产品的生产后，将授权给版权所有者 B。然后由版权所有者 B 向版权认证中心 WR 进行作品登记，并在 WR 中选择私钥 Key1 往期望保护的数字作品 AW 嵌入含有 B 标识 PIN1 的第一个数字水印 Watermarking1，再将加过数字水印的数字产品 AW1 传一份备份给 WR 的数据库中。Key1 由 B 产生，具有唯一性。

当 B 决定将其数字产品授权给数字媒体发布商 MD，让 MD 销售其作品的复制品时，B 需要将 MD 的标识 PIN2 结合私钥 Key1 对数字作品嵌入第二个数字水印 Watermarking2，用来表示对 MD 的授权和认可。MD 得到加有两个数字水印的数字作品，并可以用 B 的公钥 Key2 验证 B 确实在其数字产品的复制品中加入了 MD 的标识 Watermarking2。MD 作为 B 的数字产品销售商，可以验证第二个数字水印内容和第一个数字水印内容。

授权的 MD 将数字产品出售给授权用户 AC，为证明 AC 是经过授权的正版用户，MD 用 WR 的私钥 Key(WR)和 AC 的标识 PIN3 对数字作品嵌入第三个数字水印 Watermarking3，并将该消息通知给 WR，WR 发给 MD 一个证书，给 B 增加一份收益。

8.5 信息内容安全应用

本节主要以垃圾邮件过滤系统和网络舆情监控系统为例，从系统设计原理角度介绍信息内容安全技术的主要应用。

8.5.1 垃圾电子邮件过滤系统

当前，电子邮件以其快捷、低成本等优势已经成为人们日常生活中重要的通信手段之一。然而，近年来垃圾电子邮件日益泛滥，不仅占用了网络带宽，同时给人们的生活带来诸多困扰。从信息过滤角度，垃圾邮件过滤可看作是一个信息内容过滤问题：初始时，提供一定的垃圾邮件和非垃圾邮件给过滤系统学习，得到过滤模型；过滤的信息源是动态的邮件流；用户可以指定自己的垃圾邮件集和非垃圾邮件，供系统反馈学习，建立新的过滤模型。从信息分类角度，垃圾邮件过滤是一个二值分类问题，即将邮件分类为垃圾邮件和合法邮件的过程。本节首先介绍垃圾邮件的概念及特征，然后介绍当前实现垃圾邮件过滤常用的关键技术。

8.5.1.1 垃圾邮件的概念

当前，对垃圾邮件(spam)没有统一的定义。在《中国互联网协会反垃圾邮件规范》中对垃

圾邮件的界定如下。

（1）收件人事先没有提出要求或者同意接收的广告、电子刊物、各种形式的宣传品等宣传性的电子邮件。

（2）收件人无法拒绝的电子邮件。

（3）隐藏收件人身份、地址、标题等信息的电子邮件。

（4）含有虚假的信息源、发件人、路由等信息的电子邮件。

（5）含有病毒、恶意代码、色情、反动等不良信息或有害信息的邮件。

可见，垃圾邮件具有以下特点：未经收件人允许不请自来；具有明显的商业目的或政治目的；邮件发送量大；非法的邮件地址收集；隐藏发件人身份、地址、标题等信息；含有虚假的、误导性的或欺骗性的信息；非法的传递途径等。

垃圾邮件的处理手段包括法律和技术两方面。当前，许多国家制定了反垃圾邮件法，希望规范互联网上发送电子邮件的行为。虽然采用相应的法律和措施在一定程度上遏制了垃圾邮件泛滥，但一方面对于垃圾邮件的概念存在争议，对于像宣传品、电子期刊等这类邮件是不是垃圾邮件较难界定；另一方面国际上缺乏一个统一的反垃圾邮件法律或措施，从而使得反垃圾邮件问题收效不大。从技术角度而言，反垃圾邮件技术可分为“根源阻断”和“存在发现”两类，“根源阻断”指通过防止垃圾邮件的产生来减少垃圾邮件；“存在发现”指对已经产生的垃圾邮件进行过滤。目前后者是主流，前者还没有得到应用。利用技术来解决垃圾邮件问题是研究者关注的重点，也是本节讨论的重点。

8.5.1.2 电子邮件系统原理

要设计出好的垃圾邮件过滤方案，需要对电子邮件系统有较好的了解。理论上，电子邮件系统主要由邮件用户代理（Mail User Agent，MUA）、邮件传送代理（Mail Transmit Agent，MTA）和邮件递交代理（Mail Deliver Agent，MDA）组成。

（1）MUA：主要用来帮助用户编辑、生成、发送、接收、阅读和管理邮件，如 Outlook、Foxmail 等。在邮件系统中，用户与 MUA 打交道，从而将邮件系统的复杂性与用户隔离开。

（2）MTA：主要用来处理所有接收和发送的邮件。对于每一个外发的邮件，MTA 决定接收方的目的地。若目的地是本机，则 MTA 直接将邮件发送到本地邮箱或交给本地的 MDA 进行投递；若目的地是远程邮件服务器，则 MTA 必须使用 SMTP 协议在 Internet 上同远程主机通信。常用的 UNIX MTA 有 Sendmail、Qmail 和 Postfix 等。

（3）MDA：MTA 自己并不完成最终的邮件发送，一般通过调用其他的程序来完成最后的投递服务。这个负责邮件递交的程序是 MDA，常见的 UNIX MDA 有 Procmail 和 Binmail 等。

一般地，具体的电子邮件系统传输过程如图 8.18 所示。

简单而言，首先，邮件发送者利用本地的 MUA，按照 SMTP 将邮件发送给发送端 MTA。然后，MTA 根据邮件中的接收地址中的域名去查询域名服务器 DNS 获得接收端 MTA 的 IP 地址；发送端的 MTA 与接收端的 MTA 按照 SMTP 协议进行通信，将邮件发送给接收端的 MTA。根据 SMTP 协议的规定：若发送端的 MTA 无法直接连接到接收端的 MTA，可以通过中继 MTA 进行转发。发送端的 MTA 或中继 MTA 在发送邮件时，若发送不成功，则会尝试多次，直到发送成功或因尝试次数过多而放弃为止。这种转发方法对转发邮件来源没有限制，任何服务器都可以通过它来转发邮件，这便是开放式转发（open relay）。由于在邮件头中只记录了域名信息，而没有 IP 地址，经过转发之后无法得知邮件初始发出的 IP 地址。很多垃圾邮件制造者就是利用这一点结合伪造域名信息来隐藏自己的实际发行地址。最后，接收端

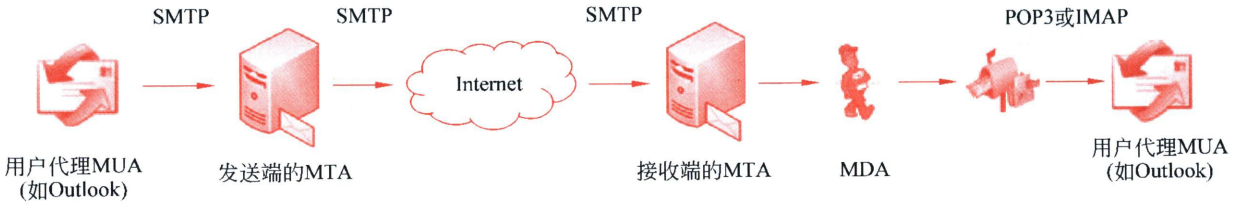

图 8.18　电子邮件系统传输过程

的 MTA 通过调用 MDA 将邮件分发到对应的邮箱中。用户通过 MUA，按照 POP3 或 IMAP 协议从邮箱中收取邮件。

从整个邮件传输过程来看，可以在其中的一个或多个环节中设置过滤器来过滤垃圾邮件。按照过滤器在邮件过滤系统中实施的主体，可以将过滤器进行如下分类。

（1）MTA 过滤：指 MTA 在会话过程中对会话的数据进行检查，对符合过滤条件的邮件进行过滤处理。一般地，MTA 过滤可以在邮件会话过程中的以下两个阶段实行：①在邮件发送 DATA 指令之前的过滤，邮件对话可以在 SMTP 连接开始、HELO/EHLO 指令、Mail From 指令和 Rcpt To 指令中对会话数据进行检查。若在检查中该会话符合过滤的条件，则按照规则采取相应的动作，如直接在会话阶段断开、发出警告代码等。②对信头和信体进行检查，即邮件在发送 DATA 指令后的过滤。实际上，邮件发送邮件数据后的检查实际上是对邮件数据传输基本完毕后进行的，因此并不能节省下被垃圾邮件占用的带宽和处理能力，只是可以让用户不再收到这些已经被过滤的垃圾邮件。

（2）MDA 过滤：指从 MTA 中接收到的邮件后，在本地或远程递交时进行检查，对于符合过滤条件的邮件进行过滤处理。大多数的 MTA 过滤器并不检查邮件的内容，对邮件内容的过滤一般由 MDA 来完成。

（3）MUA 过滤：MTA 和 MDA 过滤都是在邮件服务端的过滤，位于电子邮件服务器上，往往不能针对用户的个性化特点设置一些具有针对性的过滤规则，而用户通常希望能自主设置、管理个人过滤器的规则。该功能可通过邮件客户端 MUA 过滤来实现，通常将识别出来的垃圾邮件单独存放在一个专门的邮箱文件夹中。当前大多数邮件客户端都支持 MUA 过滤，如 Outlook、Foxmail 等。

8.5.1.3 垃圾邮件的特征分析

当前，电子邮件的主要特征模型层次分为网络层和应用层，主要考虑的因素如表 8.4 所示，其中分别用 1、2、3 表示特征的重要程度：1 表示重要性强，特征明显；2 表示重要性次之；3 表示重要性更次。特征重要性的评估直接关系到垃圾邮件衡量大小的选择。

表 8.4 垃圾邮件层次特征

层　次		特征描述	重要性
网络层		IP 地址是否可信	1
		IP 链接数量、频率是否异常	1
应用层	信头特征	X-mailer 没有或是特殊字段	2
		Mail From 字段不相同或反向解析与真实的 IP 不符或包含关键词	2
		Received：时间有误，传送时间长，其中标识的 IP 地址有误，有 3 个以上 Received 或包含关键词	1
		Reply-to：与 From 字段不相同或包含关键词	1
		Message-id 伪造，whois 查询的结果为该域名不存在	1
		Data：时间在当前时间之前	1
		Subject：包含关键词	1
		Cc：抄送人字段包含关键词	2

续表

层　次		特征描述	重要性
应用层	信体特征	信体的大小问题，过大(包含内嵌资源或是大邮件轰炸)或批量空信	1
		附件的大小问题	2
		附件的类型问题，为声音、图像、可执行文件，或包含恶意宏	1
		信体，附件包含关键词	2
		信体，附件语义分析包含垃圾信息	3

在信体特征中，信体、附件语义分析包括垃圾信息，这一特征中要求的中文文本语义分析是一个很复杂的机器学习过程。该过程能够用于自动化垃圾邮件特征的提取，再辅以人工，可实现提取大部分的垃圾邮件文本特征。中文文本由于其特殊性，文本分析比较复杂，需要先进行分词，对词性和词义标注，进而实现词汇整合，短语、句子的语义分析，最后将句子整合为句群，达到段内、文本语义分析的目的。

8.5.1.4　垃圾邮件过滤系统流程

一般地，垃圾邮件过滤系统处理流程如图 8.19 所示。电子邮件是以一定的编码方式在网络上根据 SMTP 协议进行传输的数据包。在 SMTP 会话过程中，可以根据会话过程中的 Mail From 和 Rcpt To 等会话进行过滤。然后，将得到的邮件数据包进行解码，得到普通文本格式。如上所述，电子邮件的一般格式包括信头和信体两部分，其中信头包括发件人地址、收件人地址、主题、日期、路由等重要信息，信体是邮件的正文。大部分情况下，根据信头信息即可判断一封邮件是否是垃圾邮件。故而先分离信头和信体，然后分别进行基于信头和基于内容的过滤。在基于内容的过滤中，计算机无法识别文本邮件的内容，因而首先进行分词处理，

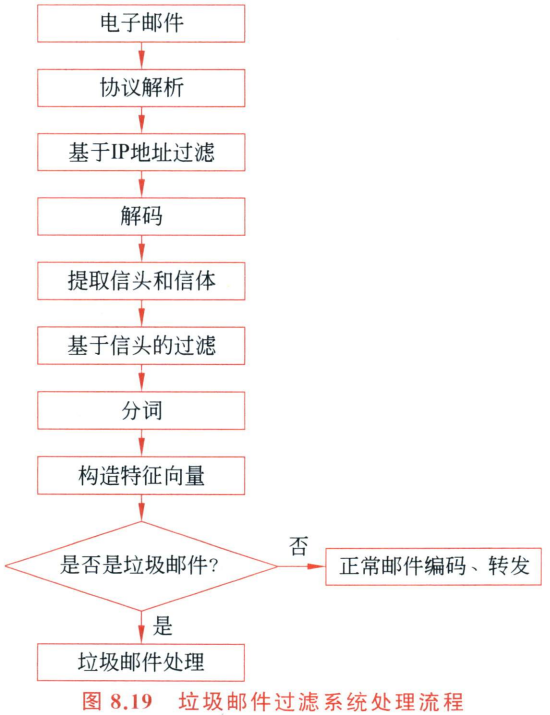

图 8.19　垃圾邮件过滤系统处理流程

同时进行必要的词义消歧，然后根据垃圾邮件的文本表示构造表示该邮件文本的特征向量，最后将文本的特征向量通过邮件过滤器，区分出正常邮件和垃圾邮件。对于正常邮件，直接编码，按照 SMTP 协议发送给邮件服务器，而对于垃圾邮件则进行过滤处理。

8.5.1.5 典型的垃圾邮件过滤技术

当前，通过过滤器实现垃圾邮件过滤的主要技术如下。

1. 基于 IP 地址的过滤技术

该类方法主要包括基于黑/白名单、实时黑名单、DNS 反向查询方法等。例如，基于黑白名单的方法首先通过维护一个黑/白名单列表，其中黑名单列表保存了已经被确认为垃圾邮件发送者的邮箱地址、邮件服务器域名和转发服务器 IP 地址等，白名单列表维持了一个信任列表，然后通过检查邮件是否来自这些邮箱或服务器来判断是否为垃圾邮件。实时黑名单（Real-time Blackhole List，RBL）是通过 DNS 查询的方式提供对某个 IP 或域名是不是垃圾邮件发送源的判断。具体而言，若某 IP 地址在某个 RBL 列表中，则查询会返回一个具体的解析结构，该邮件就会被丢弃；若该 IP 地址没有在 RBL 列表中，则查询返回一个查询错误，该邮件被认为是正常邮件。一般情况下，RBL 服务的提供和维护由比较有信誉的组织提供，如中国反垃圾邮件联盟等。DNS 反向查询通过将发送服务器的 IP 进行 DNS 反向解析，对比得到的域名与信头中其声称的是否一致来判断是否是垃圾邮件。

2. 基于关键字的过滤技术

该技术通过信头和信体中是否含有设定的关键字来判断邮件是否是垃圾邮件，然后进行相应的处理。该技术的基础是需要创建一个关键字库，一般情况下可以定义一些反映垃圾邮件特征的关键词或短语，如“免费”“特价”等。这种技术实现起来比较简单，但是缺点是需要人工维护关键字列表，并且存在较高的误判率。另外，若通过对关键字进行某些变化可以很容易避开这种检测。

3. 基于行为识别的过滤技术

通过行为识别技术可有效区分正常邮件和垃圾邮件的行为特征。一般地，行为识别技术包括信息发送过程中的各类行为因素，如发送时间、发送频度、发送 IP、发送地址、收件地址、回复地址、协议声明和指纹识别等。常见的垃圾邮件发送行为可分为以下四种。

（1）邮件滥发行为：垃圾邮件发送者登录邮件服务器进行联机查询或投递邮件，尝试各种方式投递邮件，具有发件主机异常变动等行为。

（2）邮件非法行为：垃圾邮件发送者借用各地的多个开启了 Open Relay 邮件转发功能的邮件服务器来发送邮件的行为。

（3）邮件匿名行为：发件人、收件人、发件主机或邮件传输信息刻意隐匿，使得无法追溯其来源的行为。

（4）邮件伪造行为：发件人、收件人、发件主机或邮件传输信息经过刻意伪造，经查证不属实的行为。

基于行为识别的垃圾邮件过滤技术的基本原理，如图 8.20 所示。首先通过数据采集，收集训练邮件数据集合。然后对收集到的邮件进行预处理，包括从原始邮件信息中提取信头信息、选取具有垃圾邮件可区分性的行为特征、对行为特征数据进行向量化处理和确定特征的权重信息。最终建立行为识别模型，并对测试邮件进行分类判别。

4. 基于规则的过滤技术

基于规则的过滤技术是从大量训练样本中提取有规律性的特征生成过滤规则，然后利用

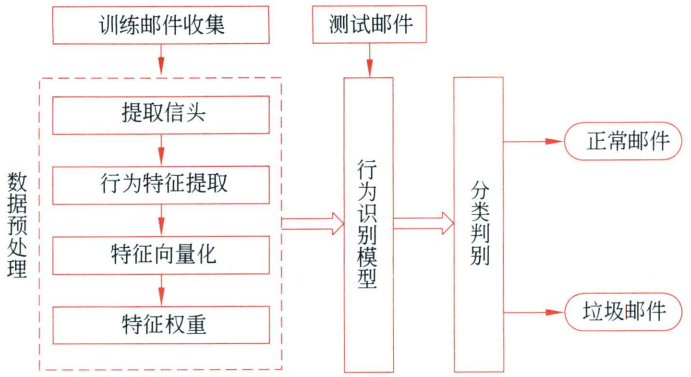

图 8.20 基于行为识别的垃圾邮件过滤技术

该规则判断新到达的邮件是不是垃圾邮件。比较简单的规则邮件过滤器的构建可由邮件服务器管理员对大量的垃圾邮件进行人工分析，从中找出垃圾邮件的明显特征，人为设定一些关于邮件头字段、正文中简单字符串的匹配规则。一般情况下，通过机器学习中的智能算法从训练集中提炼过滤规则，当前常用利用过滤规则实现垃圾邮件过滤的方法有 Ripper 方法、决策树(decision tree)方法、PART 方法、Boosting 方法、粗糙集(rough set)方法。

5. 基于统计内容的过滤技术

基于统计内容的过滤技术是将垃圾邮件过滤看成是一个二值信息分类问题，即是否是垃圾邮件。通过提取信头和信体，利用数据挖掘和机器学习的相关技术，进行训练分类。目前常见的基于统计内容的过滤技术有 KNN(K-Nearest Neighbor)、SVM(Support Vector Machine)、Rocchio 方法、神经网络方法和 Bayesian 方法等。

8.5.2 网络舆情监控与管理系统

互联网的开放性、自由性和便捷性等特点使得网络舆论的表达诉求日益多元化。人们能在网上随时随地分享自己的意见、情绪和态度，其中既包括积极的消息内容，也包括消极的消息内容。在人人都参与网络的今天，任何突发事件的发生或热点舆论的谈论都会吸引人们大量的注意力，因为其传播速度快、受众广，并且难以控制，很容易造成强烈的舆论压力。当舆论被蓄意误读后，极有可能造成不可想象的破坏，并且难以控制，将对社会稳定和国家安全造成极大的危害。因此，通过构建网络舆情监控系统，实时地采集相关信息，智能地分析信息内容，及时发现舆情危机，能为自动化解决监控、处理网络舆情提供交换的技术支持，从而很好地辅助有关部门正确处理舆情危机。

8.5.2.1 网络舆情的概念及特点

网络舆情没有统一的定义，一般地，网络舆情指由于各种事件的刺激而产生的人们对该事件的所有认知、态度、情感和行为倾向的集合，是社会不同领域在网络上的不同表现，有政治舆情、法制舆情、道德舆情和消费舆情等。

一般地，网络舆情具有以下几方面的特点。

(1) 自由性。网络的开放性使得每个人都可以成为网络信息的发布者，可以在网络上发表自己的意见。同时由于互联网的匿名特点，多数网民会自然地反映出自己的真实情绪。因此，网络舆情比较客观地反映了现实社会的矛盾，比较真实地体现了不同群体的价值。

(2) 交互性。在互联网上，网民普遍表现出强烈的参与意识。在对某一问题或事件发表

意见、进行评论的过程中，常常有许多网民参与讨论，网民之间经常形成互动场面，赞成方的观点和反对方的观点同时出现，相互探讨、争论，相互交汇、碰撞，甚至出现意见交锋。

（3）多元性。网上舆情的主题极为宽泛，话题的确定往往是自发、随意的。从舆情主体的范围来看，网民分布于社会各阶层和各个领域；从舆情的话题来看，涉及政治、经济、文化、军事、外交及社会生活的各个方面；从舆情来源上看，网民可以在不受任何干扰的情况下预先写好言论，随时在网上发布，发表后的言论可以被任意评论和转载。

（4）偏差性。由于受各种主客观因素的影响，一些网络言论缺乏理性，比较感性化和情绪化，甚至有些人把互联网作为发泄情绪的场所，通过相互感染，这些情绪化言论很可能在众人的响应下，发展成为有害的舆论。

（5）突发性。网络舆论的形成往往非常迅速，一个热点事件的存在加上一种情绪化的意见，就可以成为点燃一片舆论的导火索。当某一事件发生时，网民可以立即在网络中发表意见，网民个体意见可以迅速地汇聚起来形成公共意见。同时，各种渠道的意见又可以迅速地进行互动，从而迅速形成强大意见声势。

8.5.2.2 网络舆情监控系统架构

互联网上的信息量巨大，仅依靠人工的方法很难完成网络上海量信息的收集和处理。所以，有必要形成一套自动化网络舆情监控系统，由被动防堵转换为主动引导。一个典型的网络舆情监控系统应包括如下模块：网络舆情信息采集、网络舆情分析处理和网络舆情服务，具体如图 8.21 所示。

1. 网络舆情信息采集

一般情况下，用户按照具体的需求定制信息采集参数，包括需要监控的网站、采集频率、关注网页报道的类型及感兴趣的关键字。在参数定制好后，系统在后台运行网络舆情信息采集模块，通过各种类型的网络爬虫技术来抓取整个互联网中的所有与舆情相关的信息，并将这些信息放入信息检索库中。具体的网络爬虫技术在 8.2.2 节中已经进行了相关的介绍。总体而言，该模块主要完成以下功能。

（1）采集各种论坛、新闻留言板、博客、微博、百度贴吧等信息源的各类信息，主要以文本为主，同时也包括图像、音频和视频等多媒体信息。

（2）能够实现满足用户需求的定向网络舆情信息抓取。

（3）支持具有多线程、分布式采集功能的高速采集技术。

（4）支持具有身份验证的网络的采集，但需要提供合法的用户账号。

（5）内置自动转码功能，可以将 Big5 或 Unicode 编码统一转换为 GBK 编码进行后续处理。

2. 网络舆情分析处理

该阶段由信息检索库、舆情信息预处理、舆情信息挖掘和舆情知识库四部分组成。信息检索库主要用来存储网络爬虫抓取的海量信息；舆情知识库用来存储舆情相关信息。这里重点介绍舆情信息预处理和舆情信息挖掘两个模块。

舆情信息预处理阶段主要用来完成自动排重、网页去噪、自动分词和语义分析等。

（1）自动排重。其用来识别网络爬虫采集到的网页信息，剔除一些重复冗余的网页，以便大幅度减少网页的数量，提高网页搜索的效率，降低后续操作的工作量和存储复杂度。目前，网页自动排重的主要思路是从输入的文本中提取适当的特征；然后和以前输入的文本的特征进行比较判断。常见的网页排重算法有 DSC(Digital Syntactic Clustering)算法、改进的 DSC-

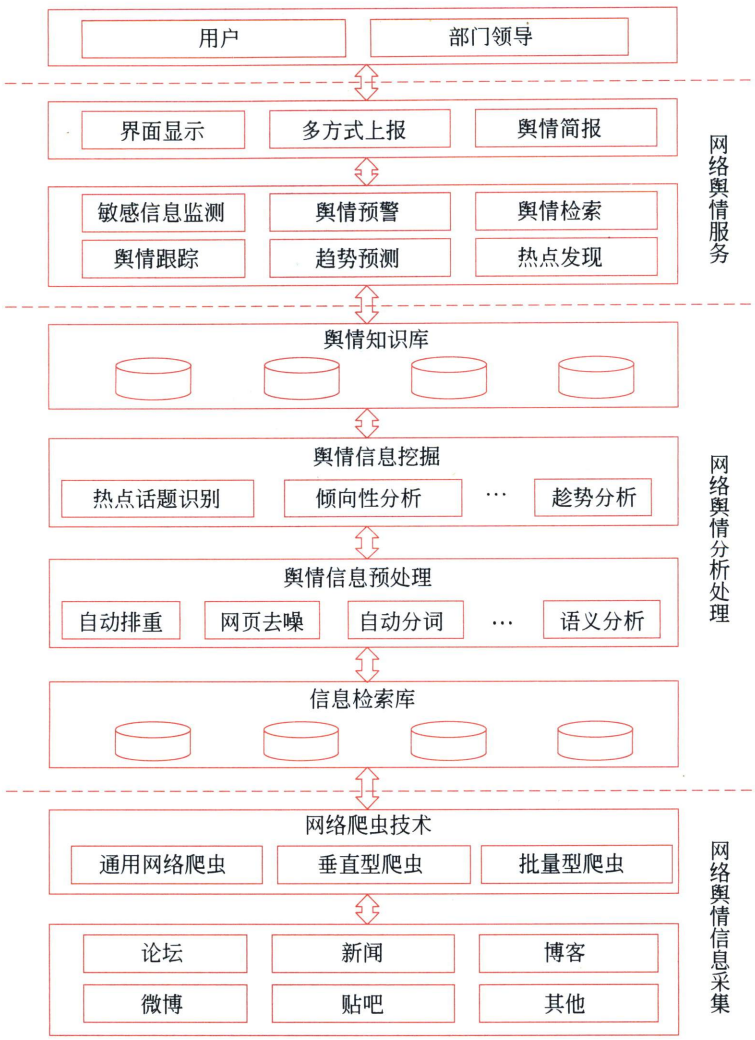

图 8.21　网络舆情监控系统架构

SS 算法(DSC-SuperShingle)、I-Match 算法、基于关键词匹配的向量空间模型检测算法等。

(2) 网页去噪。其主要用来识别并排除与网页主题无关的噪声信息，如广告信息、版权信息等，从而实现网页净化。网页噪声容易导致主题漂移，即在一个网页中存在多个主题的情况。当网页经过净化后，系统可以快速识别并提取网页中主题信息，将之作为处理对象，可提高处理结果的准确度。另外网页净化可以简化网页内标签结构的复杂度并减少网页的大小，从而节省后续处理过程的时间和空间开销。目前，常用的方法是通过构建高效的、具有自动性和可适应性的包装器来实现噪声识别和网页净化。

(3) 自动分词。利用分词技术、文本表示、特征选择等处理文本信息是后续处理过程的基础，相关的方案已经在 8.3 节中进行了介绍不再赘述。

(4) 语义分析。这是指运用各种机器学习方法，挖掘与学习文本、图像等深层次概念。对于网页文本信息而言，语义分析是在分析句子的句法结构和辨析句中每个词词义的基础上，推导句义的形式化表达。由于自然语言的复杂性，浅层语义分析的出现简化了语义分析方式。其基于一套非严格定义的标签体系，标注句子的部分成分并以标注结构作为分析结果，摒弃了深层成分和关系的复杂性，能在真实语料环境下实现快速分析，获得比深层分析更高的准确

率。通过更深层次的自然语言处理和分析，相比简单的分词和匹配技术能够更有效表达舆情信息所包含的各种情绪、意见和态度等。

舆情信息挖掘模块是在舆情信息预处理的基础上进一步分析网页相关信息，主要内容如下。

（1）热点话题识别。话题识别与跟踪（Topic Detection and Tracking，TDT）是网络舆情监控中的关键技术之一，具体指在新闻专线和广播新闻等来源的数据流中自动发现主题并把主题相关的内容联系在一起的技术。通过 TDT 能帮助人们把分散的信息有效地汇集并组织起来，从整体上了解一个事件的全部细节，以及与该事件与其他事件之间的关系，有助于进行历史性研究。目前，TDT 可应用于大规模动态信息中新热门话题发现、指定话题跟踪、实时监控关键人物动态和分析信息的倾向性、判定和预警有害话题等。

热点话题识别作为 TDT 的一种应用，构建在网络舆情信息采集和预处理的基础上，一般包括文本获取、文本表示、话题聚类和热度评估四个阶段。其中前两个阶段在上面已经进行介绍，这里仅介绍话题聚类和热度评估，一般实现框架如图 8.22 所示。

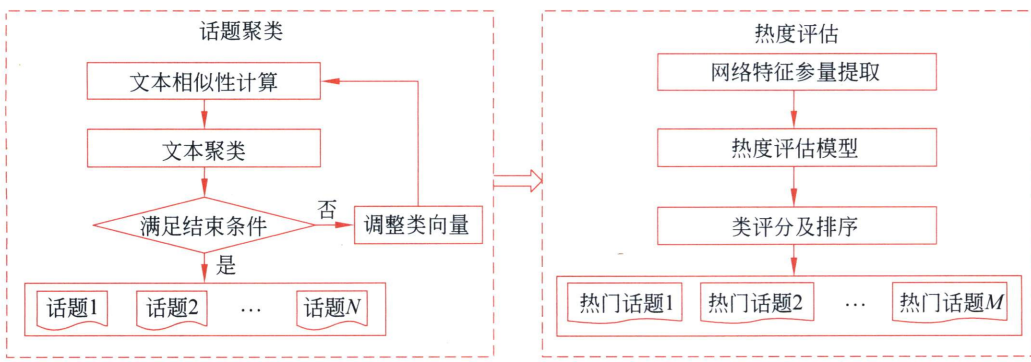

图 8.22　热点话题识别

话题聚类的核心思想是一个文本集被聚成若干称为簇的子集，每个簇中的文本之间具有较大的相似性。在基于文本表示的基础上，通过计算文本之间的相似性实现话题聚类。当前常用的相似度计算有基于距离的相似度计算方法、基于本体的语义相似度计算方法、基于索引图的概念相似度计算等。

在话题聚类之后，可得到一组用聚类中心表示的话题向量，每个话题向量包含一个特征项序列，通过热度评估模型提取出某一个时间段内的热点话题。当前，针对新闻报道所建立的热度评估模型大多结合媒体关注度和用户关注度两方面建立，通过提取网络特征参量计算媒体报道频率、话题分布率、报道时长等，显然媒体关注度的高低与网络特征参量的数值成正比，而用户关注度可以通过获取每篇报道的点击率和评论数等方法来计算。

（2）倾向性分析。网页文本倾向性分析指对说话人的态度（或称观点、情感）进行分析，即对文本中事件或产品的评论、看法等主观信息进行分析和挖掘，进而得到评价的主观倾向，如正面、负面或中立。网络舆情预处理阶段的浅层语义分析实现了一种浅层的语义理解，能够较好地为倾向分析提供良好的语言分析基础。

当前，文本倾向性分析主要包括主观文本情感分析和文本主观性分析，其中主观文本情感分析可进一步分为词语情感倾向性分析、句子情感倾向性分析、篇章情感倾向性分析和海量数据倾向性分析。

3. 网络舆情服务

网络舆情服务模块主要提供舆情跟踪、趋势预测、热点发现、敏感信息监测、舆情预警、舆情检索、舆情信息显示等功能。热点发现利用热点话题识别功能来提供热点事件的关键字，原文索引等信息。对发现的热点事件可按照热度的不同进行排序，然后以舆情简报的形式向用户或上级报道；敏感信息监测指通过信息内容的分析方式，从大量文件中发现包含敏感信息的文件和内容；舆情预警指根据相关信息重复的次数，设置一定的报警阈值，保证在较短时间内产生预警信息，使管理部门能发现并及时采取处理措施，根据信息的危险性和重要性，可分为不同级别的预警；舆情信息显示是通过一个舆情信息分析平台，利用地理信息、新闻、视频等资源，将信息以立体的、直观的、自然的方式呈现给用户。

8.6 本章小结

本章主要介绍信息内容安全的相关概念及关键技术。首先，本章介绍信息内容安全的相关概念、安全威胁及体系架构，重点阐述信息内容安全概念和信息安全之间的关系，以及信息内容安全架构。然后，以数据处理流程为主线，重点介绍信息内容安全的关键技术，包括信息内容获取技术、信息内容识别与分析和信息内容控制与管理。最后，结合两种具体的应用系统，阐述信息内容安全在实际生活中的应用。

思 考 题

1. 简述什么是信息内容安全。其与信息安全有何关系？
2. 当前信息内容安全面临哪些安全威胁？
3. 简述信息内容主动获取技术和被动获取技术的主要思想。
4. 搜索引擎的原理是什么？简述其工作流程。
5. 简述网络爬虫的工作原理，并说明爬虫的类型和抓取策略。
6. 简述网络数据包捕获的原理，并说明在 Windows 系统下有哪些网络数据捕获方法。
7. 简述当前中文分词有哪些主要的方法。比较一下它们的优缺点。
8. 文本表示有哪些模型？各自有何优缺点？
9. 当前文本特征主要的提取方法有哪些？
10. 肤色检测的步骤有哪些？当前静态肤色检测有哪些方法？
11. 什么是信息内容过滤？它与信息检索、信息分类、信息抽取有什么区别？
12. 简述信息过滤系统的工作流程。
13. 什么是信息隐藏技术？它与密码学、数字水印有何关系？
14. 信息隐藏的主要流程包括哪些部分？
15. 什么是数字水印和版权保护？请简述如何通过数字水印实现数字版权保护。
16. 当前主要的垃圾邮件过滤技术有哪些？请简述这些技术的主要思想。
17. 什么是网络舆情？其具有哪些特点？
18. 当前网络舆情架构包括哪些部分？各自主要完成哪些主要的功能？