第 11 章 人工智能安全

本章学习要点：

- 了解人工智能的概念和发展历程；
- 了解人工智能面临的安全问题；
- 了解人工智能安全框架与测评方法。

11.1 人工智能及其安全问题

11.1.1 人工智能简述

11.1.1.1 概念

人工智能(Artificial Intelligence，AI)，由“人工”和“智能”两部分组成，其以计算机科学为基础，目标是使用计算机及其相关设备模拟人的思维和智能。作为一门技术科学，人工智能既包括理论、方法，又包括技术体系和应用系统。

11.1.1.2 人工智能发展简史

按照人工智能发展的时间序列，人工智能的发展可以分为人工智能的诞生(20 世纪 50 年代)、人工智能的黄金时期(20 世纪 60 年代)、人工智能低迷期(20 世纪 70 年代)、人工智能繁荣期(20 世纪 80 年代早中期)、人工智能寒冬期(20 世纪 80 年代晚期至 20 世纪 90 年代早期)、人工智能大发展期(20 世纪 90 年代中期至今)，各个时代代表性事件如下。

1. 人工智能的诞生

在 1956 年，在美国达特茅斯学院举行的会议上，麦卡锡第一次提出了“人工智能”的概念，标志着人工智能的诞生。

2. 人工智能的黄金时期

1966 年，由系统工程师约瑟夫·魏泽堡和精神病学家肯尼斯·科尔比发布了世界上第一个真正意义上的聊天机器人 ELIZA。

1968 年，美国斯坦福国际咨询研究所开发的移动式机器人 Shakey 诞生。

3. 人工智能低迷期

20 世纪 70 年代，由于计算机内存容量、CPU 处理速度及数据存储能力的不足，人工智能发展进入瓶颈期。

4. 人工智能繁荣期

1981 年，日本研发人工智能计算机。

1984 年，美国人道格拉斯·莱纳特启动了 Cyc 项目。

1986 年，美国人查尔斯·赫尔研制出第一台商业 3D 打印机。

5. 人工智能寒冬期

1987—1993年，专家认为人工智能不会成为“下一个浪潮”，人工智能发展再次进入困境。

6. 人工智能大发展期

1997年，超级计算机“深蓝”击败国际象棋世界冠军卡斯帕罗夫。

2002年，美国iRobot公司推出吸尘器机器人Roomba。

2008年，卡内基-梅隆大学和通用公司合作开发了无人驾驶汽车Boss。

2011年，IBM公司人工智能核心技术沃森在节目Jeopardy中击败两位冠军。

2014年，人工智能软件尤金·古斯特曼（Eugene Goostman）首次通过了图灵测试，这是人工智能里程碑式的事件。

2016年，AlphaGo战胜围棋顶级棋手李世石。

2018年，谷歌公司展示了人工智能Duplex，Duplex能代替人类对外预约服务。

2022年，美国人工智能研究实验室OpenAI研发的聊天机器人程序ChatGPT问世。

11.1.1.3 人工智能的应用领域

目前，人工智能的主要应用领域有：智能医疗、智能驾驶、智能金融、智能制造、智能安防、智能教育、智能家居、智能农业等。

1. 智能医疗

智能医疗通过无线传感技术、移动互联网技术、物联网技术等实现患者、医护人员、医院、医院设备之间的动态、实时互动，实现患者就诊、看病、缴费的智能性，提高诊断的精准性、科学性，提高对患者信息采集及追踪的自动化和健康管理的智能性。根据应用的范围不同，智能医疗又可分为智能医院、智能卫生平台及智能健康系统。

2. 智能驾驶

智能驾驶包括网络导航、自主驾驶和人工干预三个环节。其中网络导航是解决在哪里、去哪里、走哪条路线的问题；自主驾驶是在智能系统控制下，车辆自动完成启动、停车、对红绿灯识别、保持行走路线、超车、鸣笛等任务；人工干预是在智能系统控制下，对外在环境（路况、天气等）做出相应的反应。

3. 智能金融

智能金融指人工智能技术与大数据技术、云计算技术、区块链技术等先进信息技术结合，实现金融业务的智能化、个性化。其应用包括对客户、操作人员的人脸识别、声音识别、虹膜识别、指纹识别等，也包括对客户的征信情况、收入、个人身份的自动获取、计算等。通过智能金融业务可以实现对客户的精准“画像”，进而实现对客户业务的精准推荐。

4. 智能制造

智能制造指人工智能技术应用于产品设计、生产制造、加工，以及服务管理的各个环节，涉及生产管理、质量控制、故障诊断等多个方面，实现制造过程的自动化和智能性。由于制造领域业务庞杂，智能制造在不同应用环境下的模式和特点也各不相同。

5. 智能安防

智能安防指人工智能技术与云计算、大数据、物联网等技术结合实现安全防护的智能性。智能安防可以用于智能交通对行驶车辆、行驶人员违章的监管，还可以用于楼宇监控及对异常人员行为的响应和报警。

6. 智能教育

智能教育指将人工智能技术应用于教育系统，为学生选择教学课程体系、推荐书籍等，并

实现对学生学习的监管、指导等的活动过程。智能教育体系可以根据学生的基础水平、爱好为其推荐教学方案、学习计划及每阶段应该读的书籍，实现学生学习的个性和差异化，因材施教；智能教育体系也可以根据学生的学习计划完成情况实时提醒学生，一些 App 也可以对学生的作业进行辅助指导。

7. 智能家居

人工智能技术与移动互联技术、物联网技术、生物识别技术等结合可以实现对家用电器的智能控制与互动。通过手机 App 可以控制家庭门禁系统、水、电以及家用电器，并可以实时监控智能家居设备的运行状态，收到智能家居设备的故障响应信息。

8. 智能农业

智能农业系统通过传感器设备采集农作物场所的温度、湿度、光照、CO_2 浓度等信息，通过物联网传递到中央控制系统，并根据相应的指标信息启动或关闭指定设备。智能农业系统可以不依赖自然环境本身的状态，而根据农作物需求提供相应的生长条件。

11.1.1.4　人工智能的体系架构

人工智能的架构可以分为基础层、技术层、应用层三层。其中，基础层包括芯片组件、数据服务、传感器、计算服务等；技术层包括机器学习、知识图谱、自然语言理解、人机交互、计算机视觉、生物特征识别、虚拟现实/增强现实等；应用层聚焦在人工智能和各行业、各领域的结合，包括硬软件产品和行业解决方案。人工智能的三层架构组成如图 11.1 所示。

应用层	软件产品	翻译软件	语音助手	网络爬虫		
	硬件产品	智能机器人	智能终端	无人驾驶车辆		
	行业解决方案	智能医疗	智能驾驶	智能金融	智能制造	
		智能安防	智能教育	智能家居	智能农业	
技术层	虚拟现实/增强现实	获取与建模技术	分析与利用技术	交换与分发技术	展示与交互技术	技术标准评价
	生物特征识别	指纹识别	人脸识别	虹膜识别	指静脉识别	声纹识别	步态识别
	计算机视觉	计算成像学	图像理解	三维视觉	动态视觉	视频编解码	
	人机交互	语音交互	情感交互	体感交互	脑机交互	
	自然语言理解	机器翻译	语义理解	问答系统		
	知识图谱	数据挖掘	信息处理	知识计量		
	机器学习	监督学习	无监督学习	强化学习		
基础层	计算服务	云计算	量子计算	其他计算服务		
	数据服务	数据采集	数据传输	数据处理		
	传感器	温度传感器	湿度传感器	光照传感器		
	芯片	GPU	FPGA	ASIC		

图 11.1　人工智能的三层架构组成

11.1.1.5　人工智能的未来发展

1. 工业 4.0

2013 年德国推出的“工业 4.0”被称为“第四次工业革命”，其核心是促进制造业智能化水平的提升，建立智慧工厂，利用信息物理融合系统(Cyber Physical System，CPS)实现整个生产上下游链条的供应、制造、销售信息的数据化、智能化，快速、高效地完成产品供应的个性化需求。“工业 4.0”的核心是：智能工厂、智能生产、智能物流，通过智能网络互联互通，提升制

造业的协作性和创造性。

2. 中国制造 2025

“中国制造 2025”又被称为中国版的“工业 4.0”，其全面贯彻党的十八大和十八届二中、三中、四中全会精神，以智能制造为主攻方向，着力发展智能装备和智能产品，推进生产过程智能化，培育新型生产方式，全面提升企业研发、生产、管理和服务的智能化水平。

3. 我国人工智能未来发展规划

经过 60 多年的发展，我国人工智能的应用已经进入一个全新的发展阶段，人工智能与新的信息技术的融合应用成为其主要特色，这些新的信息技术包括移动互联网、大数据、云计算、脑科学等。目前，人工智能在学科建设、模型构建、技术创新及软硬件等方面呈现出整体推进和快速发展的态势，推动经济社会各个领域从数字化、网络化向智能化加速发展。

目前，人工智能已经成为国际科技竞争的新焦点，成为经济发展的新引擎，提升了社会建设的精准水平，但也对原有的产业结构、法律和伦理、信息隐私等产生了强大的冲击，带来全新的安全风险挑战。因此，强化人工智能安全问题的预防与约束，最大限度降低其运行风险，是人工智能发展的前提与基础。

我国在人工智能方面有良好的基础，未来在人工智能方面建设的重点内容包括两方面：构建开放协同的人工智能科技创新体系、培育高端高效的智能经济。其中，构建开放协同的人工智能科技创新体系包括的任务有：建立新兴人工智能基础理论体系、建立新兴人工智能关键共性技术体系、统筹布局人工智能创新平台、加速培养组织人工智能高水平人才。

无论是国内还是国外，人工智能都成为各个国家未来发展的重要战略目标，各个国家已经针对人工智能制订了各自的发展规划，人工智能与其他信息技术融合应用于社会生产、生活的不同领域是未来发展的大趋势，也必将改变或影响人们未来的生活。



11.1.2 人工智能面临的安全问题

与其他应用体系不同的是，人工智能体系的运行是自动化、智能化的，对业务目标的完成过程不需要人的参与或较少需要人的参与，所以人工智能安全要求较其他体系会更高，因为一旦发现安全事件，如果安全体系不能及时发现，对人工智能运行过程或运行结果的影响将是持续长久的。

11.1.2.1 人工智能与安全的辩证关系

人工智能系统作为一个信息系统，除了会遭受传统网络攻击以外，还会遭受由于其自身特点带来的攻击。同时，人工智能技术的应用也可以实现对其他系统安全风险的防控。

人工智能安全包含的内容有以下两方面。

(1) 由于人工智能体系构建的不成熟及应用的不规范给自身带来的安全风险。

(2) 人工智能由于其本身的智能性可以应用于网络安全领域解决网络安全风险问题。

11.1.2.2 人工智能安全问题分类

人工智能安全问题可以分为人工智能安全风险、人工智能安全应用及人工智能安全管理。

1. 人工智能安全风险

人工智能的安全风险可以分为网络安全风险、数据安全风险、算法安全风险和信息安全风险。

(1) 网络安全风险指人工智能由于网络设施及软件漏洞带来的风险，以及人工智能技术由于恶意应用带来的系统风险。

(2) 数据安全风险指人工智能训练数据偏差、人为恶意篡改及人工智能应用过程中产生的隐私数据泄露带来的风险。

(3) 算法安全风险指由于人工智能算法在设计过程中的不当导致的风险，这些风险可能导致决策结果的不科学，甚至导致决策结果的重大偏差。

(4) 信息安全风险指人工智能在信息传输过程中被恶意地修改、破坏、窃取等安全问题。

2. 人工智能安全应用

人工智能安全应用可以分为网络防护、数据管理、信息审查、智能安防、金融风控、舆情监测等网络信息安全领域和社会公共安全领域的特色应用。

(1) 网络防护指将人工智能技术应用于攻击者的身份认证、入侵检测、病毒防范、安全审计、威胁预警等领域。

(2) 数据管理指利用人工智能技术特点实现数据的自动分类、泄露防控、泄露记录与追踪等，实现对数据的安全管理。

(3) 信息审查指利用人工智能模拟人的行为对信息的可靠性、可用性、安全性进行审查。

(4) 智能安防指利用人工智能的智能性，变传统的被动防御为主动的安全防控与智能预警与决策。人工智能技术可以根据业务的规范性判断是否存在恶意攻击。

(5) 金融风控指将人工智能技术应用于金融领域客户的信用评估、身份获取，构建人物画像以实现对交易的智能监管。

(6) 舆情监测指利用人工智能技术实现对网络舆情信息的获取、分析，防止不良舆情内容泛滥，提高社会治理能力。

3. 人工智能安全管理

人工智能安全管理可以分为法规政策、标准规范、技术手段、安全评估、人才培养、生态建设几个方面。目前，人工智能安全管理水平、方法措施还有待进一步提升。

(1) 法规政策是人工智能健康发展的基石。目前人工智能的应用处于快速发展阶段，人工智能体系应用范围、应用数量时刻发生着变化，人工智能应用模式、技术水平也日新月异，所以人工智能的良好运行要求制订科学合理的法律、法规、政策。

(2) 标准规范是人工智能体系有序建设的保障，需要加速人工智能体系国际标准、国内标准、行业标准的制定和完善。

(3) 技术手段指通过技术支撑确保人工智能在网络防护、数据管理、信息审查等方面功能的实现。

(4) 安全评估指通过构建安全评估指标、流程、工具，实现对人工智能系统的评估。

(5) 人才培养指通过人工智能人才培养确保人工智能体系的良好运行。目前人工智能快速发展对人才的需求与现有人才短缺是现实情况。

(6) 生态建设是通过构建人工智能体系的生态环境，保障人工智能技术在可控条件下发展。

11.1.2.3　人工智能安全现状

1. 人工智能安全面临挑战

(1) 随着人工智能建设速度加快，基础设施面临安全挑战。

(2) 因人工智能算法设计存在缺陷，新型攻击不断出现，人工智能体系设计风险严重。

（3）人工智能体系在应用时可能对物理环境、人身财产、国家安全产生威胁。

2. 人工智能安全研究现状

下面以2010—2019年十年间的人工智能安全风险、人工智能安全防御领域研究论文发文量（单位：篇）说明人工智能安全研究的发展状况，具体如图11.2所示。

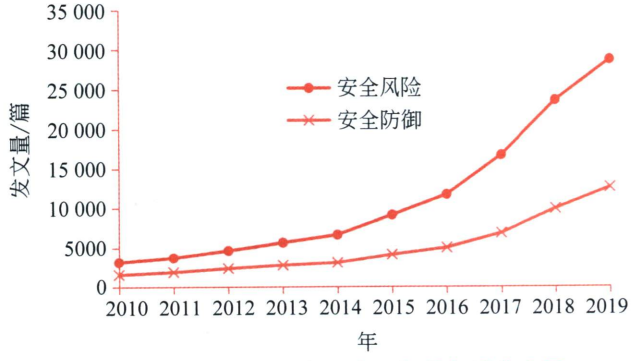


图11.2 2010—2019年间人工智能领域发文量

从图11.2可以看出，人工智能安全风险与人工智能安全防御研究论文发文量呈逐年上升趋势，可见人工智能安全作为一个新的研究领域受到学者们的高度关注。

11.2 人工智能安全框架

按照人工智能的功能，人工智能安全可以分为基础层、能力层和目标层三个层次。基础层包括人工智能安全技术及人工智能安全管理，两个维度共同决定了人工智能安全的基础水平；能力层决定人工智能安全可以达到的水平；目标层决定人工智能安全可以实现的目标。基础层是能力层的支撑，能力层是目标层的保障。其基本架构如图11.3所示。

11.2.1 基础层

1. 安全管理

（1）架构安全：指所构建的人工智能架构体系的安全，即是否进行访问权限控制、是否进行信息加密及密钥管理、是否设置登录和服务器访问日志管理、是否设置Web防火墙，是否进行网络安全漏洞测试等。

（2）人员安全：指对人工智能操作和管理人员的管控和职业道德考核等，确保工作人员按规程工作。具体包括工作人员是否经过培训并授权对人工智能体系进行使用，工作人员行为是否受到监督，工作人员职业道德考核是否合格等。

（3）流程安全：指人工智能的使用流程设置是否有安全漏洞，是否会造成数据的泄露、破坏及更改等安全风险，使用流程是否会造成错误的结果等。

（4）制度安全：指针对人工智能所建立的制度本身是否存在安全漏洞。

（5）法律法规：指与人工智能相关的法律法规是否能保障其安全，如《中华人民共和国电子签名法》《中华人民共和国数据安全法》《中华人民共和国人工智能应用法》《中华人民共和国促进和管理人工智能安全法》等法律法规对人工智能工作的支持。

（6）标准规范：目前，国内外人工智能安全已经出台了很多技术标准，如中国信息通信研究院发布的《人工智能安全标准化白皮书》。

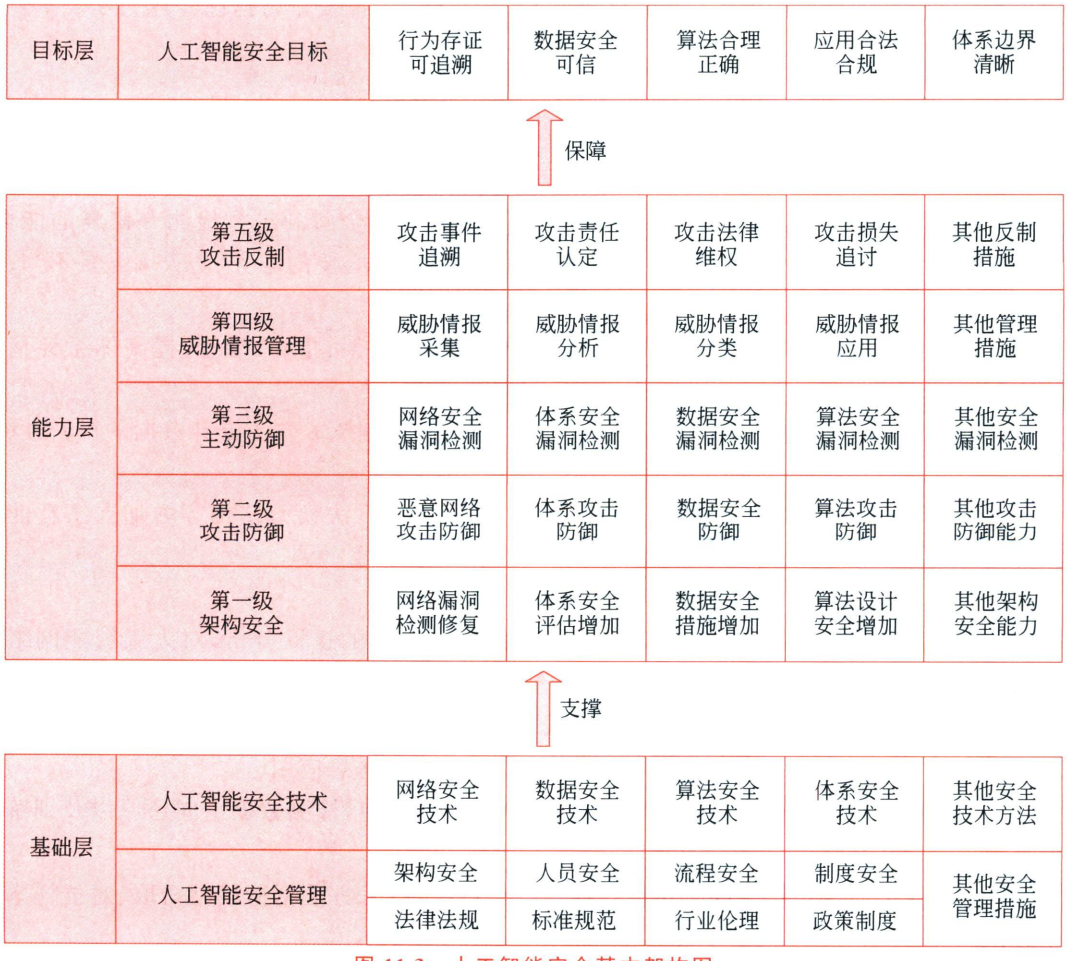


图 11.3　人工智能安全基本架构图

（7）行业伦理：指将尊重隐私、公平公正、共担责任、开放协作等伦理准则作为保障人工智能安全可靠运行的重要措施。

（8）政策制度：指国家、地方各级政府发布的关于人工智能安全的文件、规划等。

2. 安全技术

（1）网络安全技术：指人工智能体系所处网络的安全防护技术，如网络安全测评技术、网络攻击检测技术、网络安全机制等。

（2）数据安全技术：指人工智能数据的安全防护技术。包括数据溯源、数据公平性增强、数据隐私计算、数据安全测评、问题数据清洗等。

（3）算法安全技术：指针对人工智能算法设计的安全防护技术，包括算法鲁棒性增强、算法安全测评、算法公平性保障、算法知识产权保护、算法可解释性提升等。

（4）体系安全技术：指人工智能体系所布置的安全防护技术，包括模型文件校验、漏洞挖掘修复、框架体系安全部署等。

另外，由于信息技术的不断发展，一些新的技术也将服务于人工智能安全，如区块链技术。区块链是一个自动运行的智能系统，区块链技术基于其分布式账本记录原理及共识认证机制，能确保人工智能数据的可追溯性，算法或决策的科学合理，可以成为人工智能体系的信任保障基础。区块链技术与人工智能天然具有合作和无缝融合的基础，也必将成为未来人工智能的

安全技术。事实上，区块链应用于人工智能领域，保障人工智能安全可信已经成为专家学者和应用实践人员关注和探索的重点。

11.2.2 能力层

1. 第一级：架构安全

（1）网络漏洞检测修复：指对人工智能网络所存在的安全漏洞进行检测并修复的能力。具体网络漏洞包括弱口令、欺骗攻击、后门攻击、信息泄露、非必要的服务、防火墙配置不当、路由器配置不当等。

（2）体系安全评估增加：通过完善人工智能体系评估框架、指标、流程，提高体系评估的科学性、准确性。

（3）数据安全措施增加：通过引入隐私计算、数据清洗等技术方法提升数据的机密性、可用性。

（4）算法设计安全增加：通过改进算法训练方法、调整算法模型结构等增加人工智能算法的鲁棒性、可解释性和公平性等的评价值。

2. 第二级：攻击防御

（1）恶意网络攻击防御：通过对人工智能网络攻击行为的提取分析，对人工智能网络的服务器、关键信息进行攻击和窃听的行为进行捕获。

（2）体系攻击防御：通过对人工智能体系攻击行为的提取分析，在人工智能体系运行时发现口令窃取、伪造样本、破坏数据、算法后门等安全攻击和恶意应用。

（3）数据安全防御：使用数据存证溯源、安全测评等措施，检测数据逆向还原以及训练数据投毒等安全攻击行为。

（4）算法安全防御：使用算法知识产权、安全测评等技术方法抵御模型窃取、对抗样本等安全攻击。

3. 第三级：主动防御

（1）网络安全漏洞检测：对于人工智能的网络安全漏洞，人工智能安全防护工具能够及时发现并报告修复。

（2）体系安全漏洞检测：对于人工智能体系的安全漏洞，人工智能安全防护工具能够及时发现并分析漏洞发生的原因、关联影响范围、处置状态等。

（3）数据安全漏洞检测：对于人工智能数据的安全漏洞，人工智能安全防护工具能够及时发现并提供漏洞性质，以及进行数据复原措施等。

（4）算法安全漏洞检测：对于人工智能算法的安全漏洞，人工智能安全防护工具能够及时发现并分析漏洞的性质及形成原因等。

4. 第四级：威胁情报管理

（1）威胁情报采集：使用网络爬虫、关联规则等技术方法，获取人工智能潜在的威胁情报。

（2）威胁情报分析：使用情报分析工具、算法模型对人工智能威胁情报的内容及性质进行分析。

（3）威胁情报分类：按照情报分类方法，对人工智能威胁情报进行分类，以明确威胁情报可能造成的潜在威胁。

（4）威胁情报应用：将得到的威胁情报进行定性归档，根据其可能造成的影响对现有人

工智能进行管理。

5. 第五级：攻击反制

(1) 攻击事件追溯：对攻击事件形成日志文件，作为攻击事件及攻击行为查证的依据。

(2) 攻击责任认定：通过分析攻击行为，对攻击者及其应该承担的责任进行认定。

(3) 攻击法律维权：通过法律手段，对攻击者进行制约和惩罚。

(4) 攻击损失追讨：对由于攻击行为造成的损失，人工智能体系凭借攻击证据及法律裁定，要求攻击者赔偿相应的损失。

11.2.3　目标层

(1) 行为存证可追溯：人工智能安全目标要实现对攻击者行为存证并可以追溯整个攻击行为链条。

(2) 数据安全可信：人工智能安全目标要确保数据安全、真实可信。

(3) 算法合理正确：人工智能安全目标要保障所使用的算法合理，通过计算可以得到预期正确结果。

(4) 应用合法合规：人工智能安全目标要确保体系运行符合国家及行业法律法规的规定。

(5) 体系边界清晰：人工智能安全目标要确保不同人工智能体系有明确的边界，不同人工智能体系通过协议完成功能管理或数据传输等服务，安全措施的实施有明确的范围。

11.3　人工智能安全测评

人工智能安全测评是通过对人工智能系统在一定的机制下进行检查和测试，评估其安全性能，为人工智能持续健康发展提供保障。结合人工智能的结构，提出从网络安全、数据安全、算法安全及应用体系安全四方面对人工智能进行安全测评。由于目前关于人工智能安全测评还没有形成专门的标准、规范，本节参考已经发布的具体领域的测评方法进行介绍。

11.3.1　测评依据

人工智能安全测评的依据包括法律法规、技术标准、行业规范等。

1. 人工智能网络安全测评

目前这一领域测评依据主要是网络安全领域的法规与标准，比如，《信息安全等级保护管理办法》(2007 年 6 月 22 日实施)、《中华人民共和国网络安全法》(2017 年 6 月 1 日实施)、《网络安全等级保护条例(征求意见稿)》(2018 年 6 月 27 日发布)、《信息安全技术　网络安全等级保护安全设计技术要求》(GB/T 25070—2019)、《信息安全技术　网络安全等级保护基本要求》(GB/T 22239—2019)、《信息安全技术　网络安全等级保护定级指南》(GB/T 22240—2020)、《信息安全技术　网络安全等级保护测评要求》(GB/T 28448—2019)、《信息安全技术　网络安全等级保护测评过程指南》(GB/T 28449—2018)等。

2. 人工智能数据安全测评

目前这一领域的测评依据包括数据安全领域的法规与标准，比如，《中华人民共和国数据安全法》(2021 年 6 月 10 日发布)、《网络数据安全管理条例(征求意见稿)》(2021 年 11 月 14 日

发布）、《网络安全标准实践指南　网络数据分类分级指引》（2021年12月31日发布）、《网络安全标准实践指南　网络数据安全风险评估实施指引（征求意见稿）》（2023年4月18日发布）、《信息安全技术　数据安全能力成熟度模型》（GB/T 37988—2019）、《信息安全技术　声纹识别数据安全要求》（GB/T 41807—2022）、《信息安全技术　人脸识别数据安全要求》（GB/T 41819—2022）等。

3. 人工智能算法安全测评

目前这一领域的测评依据包括人工智能算法的法规与标准，比如，《人工智能深度学习算法评估规范》（T/CESA 1026—2018）、《信息技术-人工智能-机器学习模型及系统的质量要素和测试方法》（2019年4月1日发布）、《信息安全技术　人脸比对模型安全技术规范》（T/CESA 1124—2020）、《信息安全技术　机器学习算法安全评估规范（征求意见稿）》（2021年8月4日发布）等。

4. 人工智能应用体系安全测评

目前这一领域的测评依据主要是某一具体细分应用领域的测评依据，有些测评也参考信息系统的安全测评依据。比如，《常见类型移动互联网应用程序必要个人信息范围规定》（2021年5月1日施行）、《信息安全技术　远程人脸识别系统技术要求》（GB/T 38671—2020）、《智能家居网络系统安全技术要求》（T/CSHIA 001—2018）、《信息安全技术　移动智能终端安全架构》（GB/T 32927—2016）、《信息安全技术　智能家居通用安全规范》（GB/T 41387—2022）等。

11.3.2　测评对象及内容

1. 人工智能网络安全测评

测评的对象包括网络设备及安全机制：防火墙、网关、服务器、交换机、路由器、网络线路、入侵检测机制、入侵防御机制、病毒查杀机制、网络使用机制等。

测评的内容包括：网络结构安全、网络访问控制、网络安全审计、边界完整性检查、网络入侵防范、恶意代码防范、网络设备防护等。网络结构安全测评的内容包括网络拓扑结构、拥塞控制、带宽分配、域名划分等几方面；网络访问控制测评的内容包括对网络访问的策略、技术等的合理性等几方面；网络安全审计测评的内容包括网络安全的内容、范围、日志、策略等几方面；边界完整性检查测评的内容包括网络内网不同子网之间，以及网络内网与网络外网之间连接的边界完整性等几方面；网络入侵防范测评指对网络入侵所采用的防范措施（包括攻击源地址、攻击类型、攻击时间等记录情况和阻隔措施等）进行测评；恶意代码防范测评指对恶意代码防范措施应用范围、防范能力、更新情况进行测评；网络设备防护测评指对网络物理设备及软件体系所使用的安全措施（包括访问控制、数据保护、身份记录等）进行测评。

2. 人工智能数据安全测评

测评的对象包括人工智能的特征数据、运行数据、管理数据、存储数据等。

测评的内容包括数据采集安全、数据传输安全、数据交换安全、数据处理安全、数据存储安全、数据销毁安全等。

3. 人工智能算法安全测评

测评对象是人工智能领域的算法，包括决策树、随机森林、人工神经网络、K-均值、支持向量机及其他非典型算法的安全性能。

测评的内容包括人工智能算法的脆弱性与攻击威胁、算法模型泄露隐私数据、算法鲁棒性、算法运行正确性等。

4. 人工智能应用体系安全测评

测评对象是人工智能应用体系，包括人工智能软件系统、硬件设备（机房、计算机等）、管理人员、技术人员等进行安全测评。

测评的内容包括软件系统是否有安全漏洞、硬件设备是否有安全隐患、管理人员是否按要求实施管理、技术人员是否按操作规程操作系统等。

11.3.3　测评实施

在我国，《信息安全技术　信息安全风险评估方法》(GB/T 20984—2022)是典型的信息系统的安全评估规范，对现实应用起到了很重要的指导。本节在参照《信息安全技术　信息安全风险评估方法》评估方法的基础上，结合人工智能安全测评的依据、对象及内容，对人工智能安全实施测评。

人工智能安全测评的过程如下。

(1) 确定待测评人工智能安全体系。

(2) 确定人工智能安全体系测评的范围。

(3) 对人工智能安全体系进行资产识别、威胁识别、脆弱性识别。

(4) 确认已有安全措施。

(5) 计算人工智能安全风险值。

(6) 确定现有的安全风险值是否接受。

(7) 对于可以接受的风险值，进行人工智能体系风险管理；对于不可以接受的风险值，增加新的安全措施，重新测评。

(8) 生成安全风险测评文档。

人工智能安全的测评流程如图 11.4 所示。

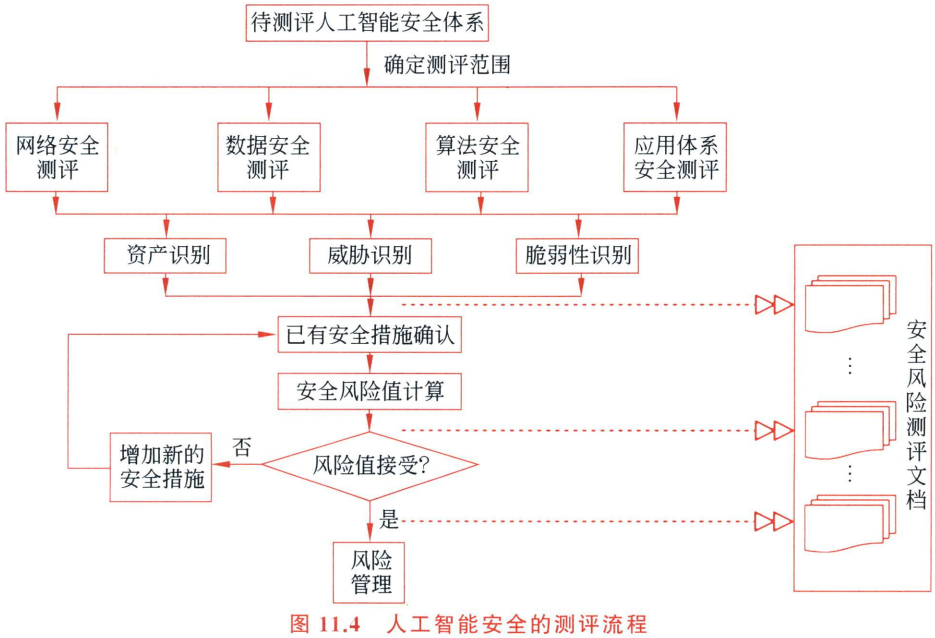


图 11.4　人工智能安全的测评流程

11.4 技术标准与法律法规

11.4.1 技术标准

1.《信息安全技术 声纹识别数据安全要求》(GB/T 41807—2022)

国家市场监督管理总局与国家标准化管理委员会于2022年10月12日联合发布了《信息安全技术 声纹识别数据安全要求》，要求该标准于2023年5月1日起实施。该标准的支撑法规是《中华人民共和国网络安全法》《中华人民共和国数据安全法》《中华人民共和国个人信息保护法》，对于人工智能领域声纹识别数据的安全管理具有指导意义。

其对“典型风险”的定义是“声纹识别数据处理活动中常见的安全风险主要包括数据的滥采滥用，数据提供给未授权的第三方，以及数据传输过程中被监听和攻击导致语音样本泄露等”。

“5 基本安全要求”中规定“开展声纹识别数据处理活动前，应按照《信息安全技术 个人信息安全影响评估指南》(GB/T 39335—2020)的规定开展个人信息安全影响评估，并形成评估报告；开展声纹识别数据处理实现产品或服务功能时，应具有明确的、必要的、难以通过其他技术替代的、直接服务于数据主体的处理目的，并确保不将声纹识别数据用于与该目的无关的其他数据处理活动”。

“6 数据收集”中规定“收集声纹语音样本前，应告知数据主体数据处理名称和联系方式，声纹识别数据的处理目的、处理方式和处理范围，处理的声纹识别数据类型、存储期限、存储地点，以及要收集的声纹语音样本内容和时长等信息，并征得数据主体的单独同意”。

“7 数据存储和传输”中规定“未经明示授权同意，不应对存储在终端设备内部的声纹识别数据有读、写、修改和删除权限”。

2.《人工智能深度学习算法评估规范》

2018年7月1日发布的《人工智能深度学习算法评估规范》(T/CESA 1026—2018)，是结合人工智能深度学习算法的特点，以及传统的可靠性评估的体系、流程而制定的。部分内容如下。

“3.5 训练数据集的影响”用于评估训练数据集带来的影响，其评估内容包括“①数据集均衡性：指数据集包含的各种类别的样本数量一致程度和数据集样本分布的偏差程度；②数据集规模：通常用样本数量来衡量，大规模数据集通常具有更好的样本多样性；③数据集标注质量：指数据集标注信息是否完备并准确无误；④数据集污染情况：指数据集被人为添加的恶意数据的程度。”

“3.7 软硬件平台依赖的影响”用于评估运行深度学习算法的软硬件平台对可靠性的影响，其评估内容包括“①深度学习框架差异：指不同的深度学习框架在其所支持的编程语言、模型设计、接口设计、分布式性能等方面的差异对深度学习算法可靠性的影响；②操作系统差异：指操作系统的用户可操作性、设备独立性、可移植性、系统安全性等方面的差异对深度学习算法可靠性的影响；③硬件架构差异：指不同的硬件架构及其计算能力、处理精度等方面的差异对深度学习算法可靠性的影响。”

“3.8 环境数据的影响”用于评估运行环境对人工智能算法的影响，其评估内容包括“①干扰数据：指由于环境的复杂性所产生的非预期的真实数据，可能影响算法的可靠性；②数据集分布迁移：算法通常假设训练数据样本和真实数据样本服从相同分布，但在算法实际使用中，数据集分布可能发生迁移，即真实数据集分布与训练数据集分布之间存在差异性；③野值

数据：指一些极端的观察值。在一组数据中可能有少数数据与其余的数据差别比较大，也称为异常观察值。”

11.4.2　法律法规

1.《生成式人工智能服务管理办法(征求意见稿)》

国家互联网信息办公室 2023 年 4 月 11 日发布《生成式人工智能服务管理办法(征求意见稿)》，目前该办法处于征求意见阶段，尚未定稿。该办法旨在规范生成式人工智能应用，并促进其健康发展。部分规定如下。

第四条规定“利用生成式人工智能生成的内容应当真实准确，采取措施防止生成虚假信息。”

第五条规定“尊重他人合法利益，防止伤害他人身心健康，损害肖像权、名誉权和个人隐私，侵犯知识产权。禁止非法获取、披露、利用个人信息和隐私、商业秘密。”

第十一条规定“提供者在提供服务过程中，对用户的输入信息和使用记录承担保护义务。不得非法留存能够推断出用户身份的输入信息，不得根据用户输入信息和使用情况进行画像，不得向他人提供用户输入信息。”

第十三条规定“提供者应当建立用户投诉接收处理机制，及时处置个人关于更正、删除、屏蔽其个人信息的请求；发现、知悉生成的文本、图片、声音、视频等侵害他人肖像权、名誉权、个人隐私、商业秘密，或者不符合本办法要求时，应当采取措施，停止生成，防止危害持续。”

2.《新一代人工智能发展规划》

国务院于 2017 年 7 月 8 日印发的《新一代人工智能发展规划》(国发〔2017〕35 号)，对新一代人工智能规划的范围、内容及具体要求做了规定。

在“建设安全便捷的智能社会”中提出：“利用人工智能提升公共安全保障能力：促进人工智能在公共安全领域的深度应用，推动构建公共安全智能化监测预警与控制体系。围绕社会综合治理、新型犯罪侦查、反恐等迫切需求，研发集成多种探测传感技术、视频图像信息分析识别技术、生物特征识别技术的智能安防与警用产品，建立智能化监测平台。加强对重点公共区域安防设备的智能化改造升级，支持有条件的社区或城市开展基于人工智能的公共安防区域示范。强化人工智能对食品安全的保障，围绕食品分类、预警等级、食品安全隐患及评估等，建立智能化食品安全预警系统。加强人工智能对自然灾害的有效监测，围绕地震灾害、地质灾害、气象灾害、水旱灾害和海洋灾害等重大自然灾害，构建智能化监测预警与综合应对平台。”

在“构建泛在安全高效的智能化基础设施体系”中提出：“统筹利用大数据基础设施，强化数据安全与隐私保护，为人工智能研发和广泛应用提供海量数据支撑。”

在“建立人工智能安全监管和评估体系”中提出：“加强人工智能对国家安全和保密领域影响的研究与评估，完善人、技、物、管配套的安全防护体系，构建人工智能安全监测预警机制。加强对人工智能技术发展的预测、研判和跟踪研究，坚持问题导向，准确把握技术和产业发展趋势。增强风险意识，重视风险评估和防控，强化前瞻预防和约束引导，近期重点关注对就业的影响，远期重点考虑对社会伦理的影响，确保把人工智能发展规制在安全可控范围内。建立健全公开透明的人工智能监管体系，实行设计问责和应用监督并重的双层监管结构，实现对人工智能算法设计、产品开发和成果应用等的全流程监管。促进人工智能行业和企业自律，切实加强管理，加大对数据滥用、侵犯个人隐私、违背道德伦理等行为的惩戒力度。加强人工智能网络安全技术研发，强化人工智能产品和系统网络安全防护。构建动态的人工智能研发应用评估评价机制，围绕人工智能设计、产品和系统的复杂性、风险性、不确定性、可解释性、潜在经

济影响等问题，开发系统性的测试方法和指标体系，建设跨领域的人工智能测试平台，推动人工智能安全认证，评估人工智能产品和系统的关键性能。”

3.《新一代人工智能伦理规范》

为深入贯彻、落实《新一代人工智能发展规划》，国家新一代人工智能治理专业委员会于2021年9月25日制定了《新一代人工智能伦理规范》，增强全社会的人工智能伦理意识与行为自觉，积极引导负责任的人工智能研发与应用活动，促进人工智能健康发展。部分内容如下。

第三条规定“保护隐私安全。充分尊重个人信息知情、同意等权利，依照合法、正当、必要和诚信原则处理个人信息，保障个人隐私与数据安全，不得损害个人合法数据权益，不得以窃取、篡改、泄露等方式非法收集利用个人信息，不得侵害个人隐私权；确保可控可信。保障人类拥有充分自主决策权，有权选择是否接受人工智能提供的服务，有权随时退出与人工智能的交互，有权随时中止人工智能系统的运行，确保人工智能始终处于人类控制之下。”

第八条规定“加强风险防范。增强底线思维和风险意识，加强人工智能发展的潜在风险研判，及时开展系统的风险监测和评估，建立有效的风险预警机制，提升人工智能伦理风险管控和处置能力。”

第十二条规定“增强安全透明。在算法设计、实现、应用等环节，提升透明性、可解释性、可理解性、可靠性、可控性，增强人工智能系统的韧性、自适应性和抗干扰能力，逐步实现可验证、可审核、可监督、可追溯、可预测、可信赖。”

第十五条规定“加强质量管控。强化人工智能产品与服务的质量监测和使用评估，避免因设计和产品缺陷等问题导致的人身安全、财产安全、用户隐私等侵害，不得经营、销售或提供不符合质量标准的产品与服务。”

11.5 ChatGPT的安全与隐私

1. 概念

ChatGPT是美国人工智能研究实验室OpenAI推出的一种人工智能技术驱动的自然语言处理工具，采用GPT-3.5模型，拥有强大的语言理解和文本生成能力，尤其是它会通过连接大量的语料库来训练模型，这些语料库包含了真实世界中的对话，使得ChatGPT具备“渊博”的知识，还能根据聊天内容进行互动，完成与人类几乎无异的聊天与交流。ChatGPT不仅是一个聊天机器人，还能执行邮件、代码、文案等的写作，以及翻译等任务。

2. 产生与发展

ChatGPT产品自2022年11月底产生以来，不断得到完善和更新，对人们生产和生活产生了很大的影响，应用领域包括客服、健康、教育、娱乐等。在ChatGPT产品产生之前，ChatGPT相关的技术、模型等经历了一定时期的发展，代表性的发展历程如下。

(1) 2015年，埃隆·马斯克等成立了OpenAI。

(2) 2018年6月，OpenAI基于Transformer模型架构，发布了语言模型GPT-1。

(3) 2019年11月，OpenAI推出GPT-2模型。

(4) 2020年6月，OpenAI推出GPT-3模型。

(5) 2022年3月，OpenAI推出GPT-3.5模型。

(6) 2022年11月，OpenAI推出ChatGPT产品，仅仅5天，注册用户人数超过100万。

(7) 2023年1月底，ChatGPT成为史上增长最快的消费者应用，当月用户超过1亿。

(8) 2023 年 2 月 2 日，微软公司宣布所有产品将全线整合 ChatGPT。

(9) 2023 年 2 月 7 日，微软公司推出由 ChatGPT 支持的搜索引擎 Bing 和 Edge 浏览器。

(10) 2023 年 2 月 8 日，微软公司将 GPT-4 模型集成到 Bing 及 Edge。

(11) 2023 年 2 月 27 日，Snapchat 推出 ChatGPT 的新版本 My AI。

(12) 2023 年 3 月 15 日，OpenAI 正式推出 GPT-4，GPT-4 支持图像和文本的输入及文本输出。

(13) 2023 年 3 月，谷歌公司宣布 ChatGPT-Bard 正式开始测试。

(14) 2023 年 4 月 23 日，ChatGPT 可以根据输入生成不同的文本。

(15) 2023 年 5 月 18 日，OpenAI 推出 ChatGPT 的 iOS 版。

目前，ChatGPT 的功能及技术还在不断地更新，其应用范围越来越广，承载的任务也越来越智能。

3. 安全与隐私问题

与其他人工智能产品一样，ChatGPT 也面临着安全与隐私问题，并且由于 ChatGPT 是一个新兴产品，其面临的安全与隐私问题会更加突出，解决好 ChatGPT 的安全与隐私问题是 ChatGPT 推广应用、功能更新的基础性保障。

ChatGPT 面临的安全问题包括恶意使用、产品安全漏洞等。

(1) 恶意使用。由于 ChatGPT 强大的智能性，有些人利用 ChatGPT 来撰写论文，有些人利用 ChatGPT 对他人进行人身攻击，有些人利用 ChatGPT 进行网络战争，等等。这类问题的解决措施是严格控制 ChatGPT 的使用权，并对 ChatGPT 的使用进行记录。

(2) 产品安全漏洞。作为一款计算机软件，ChatGPT 与其他软件一样面临着安全风险。由于 ChatGPT 不断升级、改进功能，ChatGPT 的安全漏洞也不可避免。该问题的解决措施是进行 ChatGPT 的安全审计与风险评估，发现问题及时解决。

ChatGPT 面临的隐私问题包括用户数据访问、非法入侵、互动生成隐私数据等。

(1) 用户数据访问。ChatGPT 对用户数据进行分析时，可能会造成数据被篡改、丢失，也可能会造成用户个人保密信息的泄露。该问题的解决措施是确保 ChatGPT 的使用是合法的，包括访问者身份合法、访问权限和访问流程等合法。

(2) 非法入侵。ChatGPT 面临着被不法分子或黑客控制而非法入侵用户个人数据库的风险。该问题的解决措施是采用数据加密保护、数据备份等措施。

(3) 互动生成隐私数据。ChatGPT 可以在与用户互动聊天的过程中，捕捉或分析出用户的个人数据，这些数据被利用会给用户生活、工作带来严重的不适和扰乱。该问题的解决措施是在与 ChatGPT 互动前严格确定用户的信息互动权限。

另外，基于 ChatGPT 智能性以及与用户互动频率高等特点，为了确保 ChatGPT 运行的安全及保护用户隐私，可以考虑用区块链保障 ChatGPT 相关信息的可追溯性，通过明确数据来源、归属遏制 ChatGPT 的违规使用，解决 ChatGPT 的安全与隐私问题。

11.6　本章小结

人工智能是目前一个发展非常迅速的信息应用领域，人工智能安全决定着人工智能发展、应用的质量，做好人工智能安全是保障人工智能持续健康发展的基础。本章从人工智能及其安全问题、人工智能安全框架、人工智能安全测评、人工智能安全技术标准与法律法规、

ChatGPT 的安全与隐私问题几方面对人工智能安全进行了介绍，旨在让学生掌握人工智能安全的内容、人工智能安全实现的架构体系、人工智能安全测评以及目前针对人工智能发展所制订的技术标准与法律法规，了解人工智能前沿产品 ChatGPT 的安全与隐私问题。



思 考 题

1. 什么是人工智能？概述人工智能的发展历程。
2. 论述人工智能的体系架构及组成。
3. 分析人工智能的未来发展。
4. 简述人工智能的安全问题。
5. 论述人工智能的安全框架及包含的内容。
6. 论述人工智能安全测评的内容并给出测评的流程。
7. 简述 ChatGPT 面临的安全与隐私问题。

参 考 文 献



图书资源支持

感谢您一直以来对清华版图书的支持和爱护。为了配合本书的使用，本书提供配套的资源，有需求的读者请扫描下方的“书圈”微信公众号二维码，在图书专区下载，也可以拨打电话或发送电子邮件咨询。

如果您在使用本书的过程中遇到了什么问题，或者有相关图书出版计划，也请您发邮件告诉我们，以便我们更好地为您服务。

我们的联系方式：

清华大学出版社计算机与信息分社网站：https://www.shuimushuhui.com/

地　　址：北京市海淀区双清路学研大厦 A 座 714

邮　　编：100084

电　　话：010-83470236　010-83470237

客服邮箱：2301891038@qq.com

QQ：2301891038（请写明您的单位和姓名）

资源下载：关注公众号“书圈”下载配套资源。

资源下载、样书申请

书圈

图书案例

清华计算机学堂

观看课程直播